

MR 重建中的优化算法

甘嘉程

2026 年 8-9 月

摘要

本报告基于《Advances in Magnetic Resonance Technology and Applications》第三章内容，系统梳理了 MR 图像重建中的优化算法。报告从 MR 正向模型的基本形式出发，首先讨论了最小二乘（Least Squares）重建的闭合解与迭代求解方法，包括梯度下降法（Gradient Descent）和共轭梯度法（Conjugate Gradient）的详细推导、收敛条件以及算法伪代码。随后，报告将 MR 重建形式化为正则化优化问题 $\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \{g(\mathbf{x}) + h(\mathbf{x})\}$ ，并分别讨论了光滑优化方法（Tikhonov 正则化、加速梯度法 AGM 及其 $O(1/t^2)$ 收敛性）和非光滑优化方法（近端梯度法 PGM/APGM/FISTA、交替方向乘子法 ADMM、原始-对偶 Chambolle-Pock 算法）。报告详细推导了各类算法的迭代格式、近端算子的计算、收敛性定理，并通过算法伪代码加以说明。最后简要介绍了随机梯度方法（Stochastic Gradient Descent、Adaptive Moment Estimation、Nesterov-Accelerated Adaptive Moment Estimation，缩写 SGD、Adam、NADAM）等在 MR 重建中的应用前景。本报告的特点是在保持原文数学推导和算法完整性的基础上，将其翻译为中文并保持所有公式格式与原文一致。

本章从优化理论的视角出发，系统阐述了 MR 图像重建中各类迭代算法的数学原理和收敛性质，涵盖光滑与非光滑目标函数、一阶加速方法、算子分裂技术以及原始-对偶框架，为理解现代 MR 重建算法的设计思想和实现细节提供了完整的数学基础。

1 MR 重建模型回顾与优化算法概述

首先来简要回顾第二章论述的 MR 重建问题的数学模型。MR 数据采集在 k 空间中进行，其对应于图像的 Fourier 变换。当全采样时， k 空间数据 $\mathbf{s} \in \mathbb{C}^p$ 与图像数据 $\mathbf{x} \in \mathbb{C}^n$ 间的正向模型

$$\mathbf{s} = \mathbf{F}\mathbf{x} \quad (1)$$

其中 $\mathbf{F}$ 表示二维 Fourier 变换矩阵，其元素 $F_{kr} = \exp(-i2\pi \mathbf{k}_k^T \mathbf{r}_r)$ ， $\mathbf{k}_k \in \mathbb{R}^2$ 表示第 k 个 k 空间采样点的位置（ $\mathbf{k}_k^T$ 为其转置）， $\mathbf{r}_r \in \mathbb{R}^2$ 表示第 r 个像素的空间坐标。

在并行成像中，引入线圈空间灵敏度编码矩阵 $\mathbf{C}_c$ ，其是一个块对角矩阵，其对角线块为第 c

个线圈的空间灵敏度图。第 c 个线圈的全采样 k 空间数据为

$$\mathbf{s}_c = \mathbf{F}\mathbf{C}_c\mathbf{x} \quad (2)$$

当欠采样时, $p < n$, 设 $T \geq 1$ 为接收线圈数量, 则

$$\mathbf{s}_c = \mathbf{B}\mathbf{F}\mathbf{C}_c\mathbf{x} + \boldsymbol{\epsilon}_c \quad (3)$$

其中 $\mathbf{B} \in \mathbb{R}^{p \times n}$ 为采样矩阵, $\boldsymbol{\epsilon}_c \in \mathbb{C}^p$ 为线圈测量噪声。通过将所有线圈的测量值拼接为采样向量 $\mathbf{s} = (\mathbf{s}_1, \dots, \mathbf{s}_c, \dots, \mathbf{s}_T)$, 我们得到正向模型

$$\boxed{\mathbf{s} = \mathbf{E}\mathbf{x} + \boldsymbol{\epsilon}} \quad (4)$$

其中 $\mathbf{E} = \mathbf{B}\mathbf{F}\mathbf{C}_c \in \mathbb{C}^{T \times p \times n = m \times n}$ 为编码矩阵¹, $\boldsymbol{\epsilon} \in \mathbb{C}^m$ 为总测量噪声, 通常假设为加性白 Gaussian 噪声 (Additive White Gaussian Noise, AWGN)。

本章将讨论若干 MR 图像重建的优化策略。第二章论述了 MR 图像重建的数学基础是求解逆问题², 其中采集的 MR 数据 $\mathbf{s}$ 被图像先验知识所补全。不同的优化方法基于目标函数 (即数据保真项和正则化项) 的性质而产生。此外, 现代优化方法分为基于模型的重建方法和利用数据驱动先验的方法。在本章中, 将讨论不同迭代优化算法收敛性的假设与结果。

2 最小二乘重建

考虑Equation 4即从含噪测量值 $\mathbf{s} \in \mathbb{C}^m$ 重建图像 $\mathbf{x} \in \mathbb{C}^n$ 的逆问题。当 $\mathbf{E}$ 为良态矩阵³且 $m \geq n$ 时, 使用最大似然估计 (Maximum Likelihood Estimation, MLE) 重建 $\mathbf{x}$ 。对于 AWGN 模

¹编码矩阵 $\mathbf{E}$ 无需为显式矩阵, 而是可以作为一个函数, 依次计算线圈灵敏度与图像像素乘积、Fourier 编码和子采样。

²在 MR 重建中, 逆问题的解通常通过优化一个目标函数来获得, 根据目标函数的性质 (如光滑性、凸性等), 产生了不同的优化方法。特别地, 在正则化问题中, 目标函数由数据保真项 (量化与测量数据的一致性) 和正则化项 (编码先验知识) 组成, 这种情况是普遍存在的 (见第二章)。

³良态矩阵 (Well-conditioned Matrix): 条件数 $\kappa(\mathbf{E}) = \|\mathbf{E}\| \cdot \|\mathbf{E}^\dagger\|$ 较小的矩阵。良态矩阵的测量噪声或近似误差经求解过程放大有限; 反之, 病态矩阵 (Ill-conditioned Matrix) 会放大微扰对解的影响。在全采样 (或过采样) 条件下, 良态条件保证 $\mathbf{E}$ 列满秩, 从而 $\mathbf{E}^H\mathbf{E}$ 正定可逆, Equation 5中的闭合解存在、唯一且数值稳定 (满足三个 Hadamard 条件), 确保可以使用 MLE 求解逆问题。

型，可由 MLE 推导⁴具有闭合解的最小二乘（Least Squares, LS）问题⁵⁶

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} f(\mathbf{x}) = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 \quad (5)$$

其中 $f(\mathbf{x}) = \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2$ 称为 LS 问题的目标函数。

接下来讨论 Equation 5 的求解。由于

$$\mathbf{E}^H \mathbf{E} = \sum_{c=1}^T \mathbf{C}_c^H \mathbf{F}^H \mathbf{B}^T \mathbf{B} \mathbf{F} \mathbf{C}_c \quad (6)$$

当问题维数（即 $\mathbf{E}$ 规模）很大时，Equation 6 的计算和储存具有较高复杂度。若所有采样线圈的数据均为 k-空间全采样，即 $\mathbf{B} \in \mathbb{R}^{n \times n}$ 且 $m = Tn$ ，Equation 6 可简化为对角矩阵

$$\mathbf{E}^H \mathbf{E} = \sum_{c=1}^T \mathbf{C}_c^H \mathbf{C}_c \Rightarrow \hat{\mathbf{x}} = (\mathbf{E}^H \mathbf{E})^{-1} (\mathbf{E}^H \mathbf{s}) = \left(\sum_{c=1}^T \mathbf{C}_c^H \mathbf{C}_c \right)^{-1} \sum_{c=1}^T \mathbf{C}_c^H \mathbf{F}^H \mathbf{s}_c \quad (7)$$

此时 $\hat{\mathbf{x}}$ 可以写出显式解需要满足 $\mathbf{E}^H \mathbf{E}$ 可逆，而全采样（或过采样）满足了这一条件。若使用欠采样并行采集，即 $\mathbf{B} \in \mathbb{R}^{p \times n}$ 且 $p < n$ ，则无法显式写出 $\mathbf{E}^H \mathbf{E}$ 及其逆，故也无法写出 $\hat{\mathbf{x}}$ 的显式解，需用梯度下降法或共轭梯度法等迭代方法求解 Equation 5 中的 LS 问题。接下来我们将逐一讨论。

2.1 梯度下降法

梯度下降（Gradient Descent, GD）法求解 LS 问题的基本原理是：在当前估计处计算目标函数的梯度，并以适当的步长沿梯度的负方向迭代更新估计。在这个过程中，GD 通过迭代尝试找到满足收敛条件的最小的 $\hat{\mathbf{x}}$ ，而负梯度的使用正是为了不断向下放缩 $\mathbf{x}_i$ 。

具体来说，对 Equation 5 中的 LS 目标函数 Taylor 展开到一阶

$$f(\mathbf{x}_{t-1} - \gamma \hat{\mathbf{e}}) \approx f(\mathbf{x}_{t-1}) - \gamma \hat{\mathbf{e}}^H \nabla f(\mathbf{x}_{t-1}) \quad (8)$$

其中 $\hat{\mathbf{e}}$ 为单位向量。代入其梯度 $\nabla f(\mathbf{x}) = \mathbf{E}^H (\mathbf{E}\mathbf{x} - \mathbf{s})$ ⁷ 可得，在第 t 次 GD 迭代中，当前估计 $\mathbf{x}_{t-1}$ 沿负梯度方向更新的估计

$$\mathbf{x}_t = \mathbf{x}_{t-1} - \gamma_t \nabla f(\mathbf{x}_{t-1}) = \mathbf{x}_{t-1} - \gamma_t \mathbf{E}^H (\mathbf{E}\mathbf{x}_{t-1} - \mathbf{s}) \quad (9)$$

⁴推导过程见第二章。

⁵勘误：原文 p.61(3.4) 出现 $\frac{1}{2}$ 因子，与第二章 (28) 式系数不同。实际上，对图像的估计 $\hat{\mathbf{x}}$ 取目标函数最小值点，而目标函数整体缩放不影响最小值点，故两式的解相同。而本章加入 $\frac{1}{2}$ 因子后，目标函数的梯度为 $\mathbf{E}^H (\mathbf{E}\mathbf{x} - \mathbf{s})$ （推导过程见第二章），与梯度下降（Equation 9）更新方向一致。而在 GD 迭代中，目标函数缩放因子的差异被步长 γ 吸收：本章收敛条件 Equation 15 包含了缩放因子的倒数，若按第二章的写法则为 $0 < \gamma \leq 1/\lambda_{\max}(\mathbf{E}^H \mathbf{E})$ 。

⁶勘误：最小二乘的目标函数 $\frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2$ 为实值函数，本章所有梯度结果都应取实部。在本文中沿用了原文的表述，省略了取实部。

⁷推导过程见第二章。

其中 $\gamma_t > 0$ 为步长，可在每次迭代时调整或保持固定。GD 的收敛性和收敛速度取决于步长选择，步长过大可能导致发散，步长过小则收敛缓慢。

接下来讨论 GD 迭代解 Equation 9 收敛于 LS 问题 Equation 5 的解的条件。假设 GD 的初值为零向量 $\mathbf{x}_0 = \mathbf{0}$ ，且对所有 t 有 $\gamma_t = \gamma$ ，则递归写出

$$\mathbf{x}_t = (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}) \mathbf{x}_{t-1} + \gamma \mathbf{E}^H \mathbf{s} = \gamma \sum_{k=0}^{t-1} (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E})^k \mathbf{E}^H \mathbf{s} \quad (10)$$

由于当谱范数 $\|\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}\|_2 < 1$ 时⁸，矩阵几何级数 $\sum_k (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E})^k$ 收敛于 $(\gamma \mathbf{E}^H \mathbf{E})^{-1}$ ，此时

$$\lim_{t \rightarrow \infty} \mathbf{x}_t = \gamma (\gamma \mathbf{E}^H \mathbf{E})^{-1} \mathbf{E}^H \mathbf{s} = (\mathbf{E}^H \mathbf{E})^{-1} \mathbf{E}^H \mathbf{s} \quad (13)$$

即 GD 收敛于 Equation 5 的 LS 解。

记 Hermitian 正定矩阵 $\mathbf{E}^H \mathbf{E}$ 的特征值为 $0 < \lambda_1 \leq \dots \leq \lambda_n = \lambda_{\max}(\mathbf{E}^H \mathbf{E})$ ，则 $\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}$ 的特征值为 $1 - \gamma \lambda_i$ ($i = 1, \dots, n$)。对 Hermitian 矩阵⁹，收敛条件

$$\|\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}\|_2 = \max |\lambda_i (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E})| = \max |1 - \gamma \lambda_i| < 1 \quad (14)$$

要求所有特征值满足 $|1 - \gamma \lambda_i| < 1$ ，则¹⁰

$$0 < \gamma \lambda_i < 2 \quad \Rightarrow \quad \gamma < \frac{2}{\lambda_i}, \quad \forall i \quad \Leftrightarrow \quad \boxed{0 < \gamma < \frac{2}{\lambda_{\max}(\mathbf{E}^H \mathbf{E})}} \quad (15)$$

需要强调：1) 受 $\mathbf{E}$ 规模和 γ 的影响，GD 法可能不收敛或收敛非常缓慢；2) 上述讨论基于 GD 迭代解初值的选择，因此选定不同初值也可能影响 GD 法的收敛情况。

⁸谱范数 (Spectral Norm)：矩阵 $\mathbf{A}$ 的谱范数由向量 ℓ_2 范数诱导，定义为

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|_2}{\|\mathbf{x}\|_2} \quad (11)$$

表示矩阵作用于向量后放大向量长度的最大倍数。 $\mathbf{A}$ 的谱范数等于其最大奇异值

$$\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^H \mathbf{A})} \quad (12)$$

总的来说，向量范数衡量向量自身的长度（如 ℓ_1 范数为分量绝对值之和， ℓ_2 范数为欧氏长度），而矩阵范数衡量矩阵对向量的拉伸能力。

⁹对 Hermitian 矩阵 $\mathbf{A}$ ，谱范数等于特征值绝对值中的最大值，即 $\|\mathbf{A}\|_2 = \max |\lambda_i(\mathbf{A})|$ 。利用该性质可将范数条件转化为特征值条件 $|1 - \gamma \lambda_i| < 1$ 。

¹⁰勘误：p.62(3.8) 对 γ 取值范围上界取等。事实上，当 $\gamma = 2/\lambda_{\max}$ 时， $1 - \gamma \lambda_{\max} = -1$ ，谱范数恰为 1，几何级数不收敛。因此，本文中 γ 取值范围为严格开区间。

2.2 线性共轭梯度法

共轭梯度（Conjugate Gradient, CG）法适用于对称正定矩阵，其核心思路是：在每次迭代中，沿一个与所有先前迭代更新方向共轭的方向更新估计。这种迭代思路确保 CG 法在求解具有 n 个方程的方程组时在最多 n 次迭代内收敛。

设算符 $\mathcal{A}$ 由一个 $n \times n$ 对称正定矩阵定义，给定线性系统

$$\mathbf{y} = \mathcal{A}(\mathbf{x}) \quad (16)$$

CG 法（详见算法 1）的步骤是：（1）每次 CG 迭代需要一次系统算子 $\mathcal{A}(\cdot)$ 的应用；（2）步长 α_t 通过最小化残差 $\|\mathbf{r}_t\|_2^2$ 在搜索方向 $\mathbf{p}_t$ 上的二次型来解析计算，即 $\alpha_t = \|\mathbf{r}_t\|_2^2 / \mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t)$ ，这等价于在当前搜索方向上的一维精确线搜索；（3） β_t 的选择（Fletcher-Reeves 公式）确保新搜索方向 $\mathbf{p}_{t+1}$ 与所有先前方向关于 $\mathcal{A}$ 共轭，即 $\mathbf{p}_i^T \mathcal{A}(\mathbf{p}_j) = 0$ ($i \neq j$)。注意，Equation 5 中给出的 LS 解可写为如下线性方程组

$$\underbrace{\mathbf{E}^H \mathbf{s}}_{\mathbf{y}} = \underbrace{\mathbf{E}^H \mathbf{E} \mathbf{x}}_{\mathcal{A}(\mathbf{x})}, \quad (17)$$

这可用算法 1 中的 CG 法求解。注意我们不需要计算或应用 $\mathbf{E}^H \mathbf{E}$ 作为显式矩阵；我们可以使用一个涉及逐元素乘法和 FFT 的函数来计算矩阵乘法的效果。

算法 1 求解 $\mathbf{y} = \mathcal{A}(\mathbf{x})$ 的共轭梯度法

input: 初值 $\mathbf{x}_0$ 和残差 $\mathbf{r}_0 = \mathcal{A}(\mathbf{x}_0) - \mathbf{y}$

```

1:  $t \leftarrow 0$ 
2:  $\mathbf{p}_0 \leftarrow \mathbf{r}_0$ 
3: repeat
4:    $\alpha_t \leftarrow \frac{\|\mathbf{r}_t\|_2^2}{\mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t)}$ 
5:    $\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t + \alpha_t \mathbf{p}_t$ 
6:    $\mathbf{r}_{t+1} \leftarrow \mathbf{r}_t - \alpha_t \mathcal{A}(\mathbf{p}_t)$ 
7:   if  $\|\mathbf{r}_{t+1}\|_2^2 \leq \text{阈值}$  then
8:     break
9:   end if
10:   $\beta_t \leftarrow \frac{\|\mathbf{r}_{t+1}\|_2^2}{\|\mathbf{r}_t\|_2^2}$ 
11:   $\mathbf{p}_{t+1} \leftarrow \mathbf{r}_{t+1} + \beta_t \mathbf{p}_t$ 
12:   $t \leftarrow t + 1$ 
13: until 满足收敛/终止条件
```

2.3 非线性共轭梯度法

从目前的讨论来看，可以将 CG 视为二次函数 $f(\mathbf{x}) = \|\mathcal{A}(\mathbf{x}) - \mathbf{y}\|^2$ 的极小化器。然而，CG 可推广到极小化任何可计算梯度的连续函数 $f(\mathbf{x})$ 。对于非线性 CG 法，我们遵循算法 2。与线性版本的 CG 不同，多年来已发展出若干计算 β 的表达式用于非线性 CG。四个著名的公式由 Fletcher-Reeves

(FR)、Polak-Ribière (PR)、Hestenes-Stiefel (HS) 和 Dai-Yuan (DY) 给出：

$$\begin{aligned}\beta_{t+1}^{\text{FR}} &= \frac{\mathbf{r}_{t+1}^T \mathbf{r}_{t+1}}{\mathbf{r}_t^T \mathbf{r}_t}, & \beta_{t+1}^{\text{PR}} &= \frac{\mathbf{r}_{t+1}^T (\mathbf{r}_{t+1} - \mathbf{r}_t)}{\mathbf{r}_t^T \mathbf{r}_t}, \\ \beta_{t+1}^{\text{HS}} &= \frac{\mathbf{r}_{t+1}^T (\mathbf{r}_{t+1} - \mathbf{r}_t)}{-\mathbf{p}_t^T (\mathbf{r}_{t+1} - \mathbf{r}_t)}, & \beta_{t+1}^{\text{DY}} &= \frac{\mathbf{r}_{t+1}^T \mathbf{r}_{t+1}}{-\mathbf{p}_t^T (\mathbf{r}_{t+1} - \mathbf{r}_t)}.\end{aligned}\quad (18)$$

由于一般函数 f 可能具有许多局部极小值，无法保证 CG 收敛到全局极小值。线搜索¹¹可用于在 CG 中寻找 α_t 。

算法 2 极小化连续函数 $f(\mathbf{x})$ 的共轭梯度法

input: 初始值 $\mathbf{x}_0$

```

1:  $t \leftarrow 0$ 
2:  $\mathbf{p}_0 \leftarrow \mathbf{r}_0 \leftarrow -\nabla f(\mathbf{x}_0)$ 
3: repeat
4:    $\alpha_t \leftarrow \arg \min_{\alpha_t} f(\mathbf{x}_t + \alpha_t \mathbf{p}_t)$  ▷ 通过线搜索
5:    $\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t + \alpha_t \mathbf{p}_t$ 
6:    $\mathbf{r}_{t+1} \leftarrow -\nabla f(\mathbf{x}_{t+1})$ 
7:   if  $\|\mathbf{r}_t\|_2^2 \leq \text{阈值}$  then
8:     break
9:   end if
10:   $\beta_{t+1} \leftarrow \beta_{t+1}^{\text{formula}}$  ▷ 使用 FR、PR、HS、DY 等公式
11:   $\mathbf{p}_{t+1} \leftarrow \mathbf{r}_{t+1} + \beta_{t+1} \mathbf{p}_t$ 
12:   $t \leftarrow t + 1$ 
13: until 满足收敛/终止条件

```

3 基于模型的重建

当 $m < n$ 时，由于逆问题的不适定性，最小二乘问题已知是次优的。我们可以将一般恢复问题表述为以下正则化优化问题¹²：

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} f(\mathbf{x}) \quad \text{其中} \quad f(\mathbf{x}) = g(\mathbf{x}) + h(\mathbf{x}), \quad (20)$$

其中 g 是量化与观测数据 $\mathbf{s}$ 一致性的数据保真项， h 是编码先验知识的正则化器。

在本节中，我们讨论求解形式为 (Equation 20) 的问题的优化方法。我们首先讨论适用于可微函数 f 的传统光滑优化方法。然后考虑适用于正则化器不可微的问题的非光滑优化方法。

¹¹线搜索 (Line Search): 在 CG 中用于寻找 α_t ，该操作需要求零点。两种著名的迭代线搜索方法是 Newton-Raphson 法和割线法。两种方法都需要 f 关于 α 的 Hessian 矩阵的存在性。然而，Newton-Raphson 法使用二阶导数，而割线法使用一阶导数近似二阶导数。虽然 Newton-Raphson 法收敛快得多，但计算代价高昂。

¹²正则化优化问题与 MAP 估计：优化问题 $\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \{g(\mathbf{x}) + h(\mathbf{x})\}$ 可被识别为 $\mathbf{x}$ 的最大后验概率 (Maximum a Posteriori, MAP) 估计器，其中

$$g(\mathbf{x}) = -\log p_{\mathbf{s}|\mathbf{x}}(\mathbf{s}|\mathbf{x}), \quad h(\mathbf{x}) = -\log p_{\mathbf{x}}(\mathbf{x}), \quad (19)$$

$p_{\mathbf{s}|\mathbf{x}}$ 为似然， $p_{\mathbf{x}}$ 为图像先验。自然地，Equation 5 中的 LS 是具有均匀图像先验的 AWGN 下 MAP 的特例。

3.1 光滑优化

Tikhonov 正则化是稳定不适定逆问题的最古老且最著名的技术之一 [17, 18]。在其经典形式中，它寻求极小化 LS 数据保真项与二次正则化器之和

$$g(\mathbf{x}) = \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 \quad \text{和} \quad h(\mathbf{x}) = \frac{\lambda}{2} \|\Phi\mathbf{x}\|_2^2, \quad (21)$$

其中 $\lambda > 0$ 表示正则化参数， Φ 表示稀疏变换。Tikhonov 解退化为以下闭合形式表达式¹³：

$$\hat{\mathbf{x}} = (\mathbf{E}^H \mathbf{E} + \lambda \Phi^H \Phi)^{-1} (\mathbf{E}^H \mathbf{s}), \quad (23)$$

这可以使用算法 1 中的共轭梯度（CG）法计算 [19-21]。

在更一般的设置中，正则化器 h 对应非二次可微函数。一个广泛用于极小化此类函数的算法是加速梯度法（Accelerated Gradient Method, AGM）[22, 11]，其迭代可写为

$$\mathbf{x}_t = \mathbf{z}_{t-1} - \gamma_t \nabla f(\mathbf{z}_{t-1}), \quad (24)$$

$$\mathbf{z}_t = \mathbf{x}_t + \frac{q_{t-1} - 1}{q_t} (\mathbf{x}_t - \mathbf{x}_{t-1}), \quad (25)$$

其中 $t = 1, 2, 3, \dots$ ， $\mathbf{x}_0 = \mathbf{z}_0 \in \mathbb{C}^n$ 为初始化， $\gamma_t > 0$ 为步长参数。注意，当对所有 $t \geq 1$ 过度松弛参数 $q_t = 1$ 时，AGM 退化为传统的梯度下降。然而，通过在每次迭代中自适应调整 $\{q_t\}$ ，AGM 寻求相对于 GD 加速收敛。 $\{q_t\}$ 的一个广泛使用的选择是设置为

$$q_t = \frac{1}{2} \left(1 + \sqrt{1 + 4q_{t-1}^2} \right) \quad \text{从} \quad q_0 = 1 \quad \text{开始}. \quad (26)$$

AGM 的步长参数通常固定在一个充分小的值 $\gamma > 0$ ，或通过回溯线搜索自适应调整 [9]。回溯线搜索寻求确保目标函数在每次迭代中有充分的下降¹⁴。

AGM 的收敛速度可针对凸光滑函数进行精确刻画。考虑优化问题的以下条件：

假设 1. 函数 $f = g + h$ 连续可微且凸。此外，梯度 ∇f 是 Lipschitz 连续的，具有常数 $L > 0$ 。

这是优化文献中广泛使用的假设，其简单断定了目标函数的凸性和光滑性。当 f 二次连续可微时，假设 1 等价于条件 $\mathbf{0} \preceq \nabla^2 f(\mathbf{x}) \preceq L\mathbf{I}$ ，其中 $\nabla^2 f(\mathbf{x}) \in \mathbb{R}^{n \times n}$ 是 f 的 Hessian 矩阵¹⁵。

¹³Tikhonov 闭合解的推导：对 $f(\mathbf{x}) = \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 + \frac{\lambda}{2} \|\Phi\mathbf{x}\|_2^2$ 求梯度并令其为零：

$$\nabla f(\mathbf{x}) = \mathbf{E}^H (\mathbf{E}\mathbf{x} - \mathbf{s}) + \lambda \Phi^H \Phi \mathbf{x} = \mathbf{0} \implies (\mathbf{E}^H \mathbf{E} + \lambda \Phi^H \Phi) \hat{\mathbf{x}} = \mathbf{E}^H \mathbf{s}, \quad (22)$$

这与第二章中 Tikhonov 正则化的正规方程（??）一致。

¹⁴回溯线搜索的 Armijo 条件：给定梯度向量 $\nabla f(\mathbf{z}_{t-1})$ 、初始步长 $\gamma_t > 0$ 以及参数 $\theta \in (0, 1/2]$ 和 $\beta \in (0, 1)$ ，回溯执行如下：

当 $f(\mathbf{z}_{t-1} - \gamma_t \nabla f(\mathbf{z}_{t-1})) > f(\mathbf{z}_{t-1}) - \theta \gamma_t \|\nabla f(\mathbf{z}_{t-1})\|_2^2$ 执行 $\gamma_t \leftarrow \beta \gamma_t$ 。

对于光滑函数 f ，该 while 循环保证在 γ_t 充分小的值时终止。

¹⁵Lipschitz 连续梯度： $\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|_2 \leq L \|\mathbf{x} - \mathbf{y}\|_2$ 对所有 $\mathbf{x}, \mathbf{y}$ 成立。 L 称为 Lipschitz 常数，它限制了梯度变

假设 2. 函数 f 具有有限最小值 $f^* = f(\mathbf{x}^*)$ 在某个 $\mathbf{x}^* \in \mathbb{C}^n$ 处取得, 使得 $\|\mathbf{x}_0 - \mathbf{x}^*\|_2 \leq R$ 。

第二个假设简单地断言存在极小值点, 其到初始化 $\mathbf{x}_0$ 的距离有界。我们可以陈述以下著名的收敛结果 [11]:

定理 1. 在假设 1-2 下, 使用固定步长 $0 < \gamma \leq 1/L$ 运行 AGM $T \geq 1$ 次迭代。则该方法的迭代满足

$$\boxed{f(\mathbf{x}_{t-1}) - f^* \leq \frac{2R^2}{\gamma(t+1)^2}}. \quad (27)$$

如 Nesterov[11] 所示, AGM 在光滑凸优化中实现了一阶方法的最优 $O(1/t^2)$ 收敛速度¹⁶。优化梯度法 (Optimized Gradient Method, OGM) [23] 是 AGM 的一种最新替代方案, 具有类似的每次迭代复杂度, 但相对于定理 1 的 $2LR^2$, 其常数因子 LR^2 更优, 可使用步长参数 $\gamma = 1/L$ 实现。

3.2 非光滑优化

MRI 中许多广泛使用的正则化器 $h(\cdot)$ 是非光滑的。一些著名的例子包括全变分 (Total Variation, TV) [24, 6]、总广义变分 (Total Generalized Variation, TGV) [25, 26] 和 Hessian Schatten-范数 [27, 28]。例如, 各向异性 TV 正则化的 MRI 重建可用以下项来表述

$$g(\mathbf{x}) = \frac{1}{2}\|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 \quad \text{和} \quad h(\mathbf{x}) = \lambda\|\Phi\mathbf{x}\|_1, \quad (28)$$

其中 $\lambda > 0$ 为正则化参数, Φ 表示沿图像 $\mathbf{x}$ 的每个维度计算的有限差分。

广泛使用的正则化器的不可微性导致了近端算法 [29] 在图像重建中的广泛采用, 这些算法无需对 h 求导。在此背景下, 两个广泛使用的算法是近端梯度法 (Proximal Gradient Method, PGM) [30-33] 和交替方向乘子法 (Alternating Direction Method of Multipliers, ADMM) [34-36]。使非光滑正则化器的优雅处理成为可能的关键概念是近端算子 [37]¹⁷, 定义为

$$\text{prox}_{\lambda h}(\mathbf{z}) = \arg \min_{\mathbf{x} \in \mathbb{C}^n} \left\{ \frac{1}{2}\|\mathbf{x} - \mathbf{z}\|_2^2 + \lambda h(\mathbf{x}) \right\}, \quad \lambda > 0, \mathbf{z} \in \mathbb{C}^n. \quad (29)$$

到子集 $\mathcal{X} \subseteq \mathbb{C}^n$ 的投影是 $h(\cdot) = 1_{\mathcal{X}}(\cdot)$ 的近端算子, 其中 $1_{\mathcal{X}}(\cdot)$ 为示性函数¹⁸, 对任何 $\mathbf{x} \in \mathcal{X}$ 取值为 0, 而对 $\mathbf{x} \notin \mathcal{X}$ 取值为 $+\infty$ 。尽管近端算子可为非凸函数定义, 但当 h 为正常、闭合且凸时, 其对每个 $\mathbf{z} \in \mathbb{C}^n$ 的存在性和唯一性得以保证 [38]。

化的剧烈程度。对于二次函数 $f(\mathbf{x}) = \frac{1}{2}\|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2$, 有 $L = \lambda_{\max}(\mathbf{E}^H \mathbf{E})$ 。

¹⁶最优一阶方法: Nesterov 的里程碑式结果证明, 对于光滑凸函数, 任何仅使用梯度信息的一阶方法, 其收敛速度不可能优于 $O(1/t^2)$ 。AGM 通过巧妙的“动量”外推 (Equation 25) 恰好达到此下界, 而标准 GD 仅有 $O(1/t)$ 的收敛速度。

¹⁷近端算子的直观理解: (1) $\text{prox}_{\lambda h}(\mathbf{z})$ 寻求在“接近” $\mathbf{z}$ (通过 $\frac{1}{2}\|\mathbf{x} - \mathbf{z}\|_2^2$ 项) 与“使 $h(\mathbf{x})$ 小” (通过 $\lambda h(\mathbf{x})$ 项) 之间的平衡。(2) 当 $h(\cdot) = 1_{\mathcal{X}}(\cdot)$ 为集合 $\mathcal{X}$ 的示性函数时, 近端算子退化为到 $\mathcal{X}$ 的投影。(3) 近端算子也可解释为 AWGN 去噪问题 $\mathbf{z} = \mathbf{x} + \boldsymbol{\eta}$ (其中 $\boldsymbol{\eta} \sim \mathcal{CN}(\mathbf{0}, \lambda \mathbf{I})$, $\mathbf{x} \sim p_{\mathbf{x}}$) 的 MAP 估计器, 只需令 $h(\mathbf{x}) = -\log p_{\mathbf{x}}(\mathbf{x})$ 。

¹⁸示性函数: $1_{\mathcal{X}}(\mathbf{x}) = 0$ 当 $\mathbf{x} \in \mathcal{X}$, $1_{\mathcal{X}}(\mathbf{x}) = +\infty$ 当 $\mathbf{x} \notin \mathcal{X}$ 。此时近端算子退化为 $\text{prox}_{1_{\mathcal{X}}}(\mathbf{z}) = \arg \min_{\mathbf{x} \in \mathcal{X}} \|\mathbf{x} - \mathbf{z}\|_2^2$, 即到集合 $\mathcal{X}$ 的欧氏投影。

算法 3 总结了 PGM 和加速 PGM (Accelerated Proximal Gradient Method, APGM)¹⁹ (也称 FISTA), 其中后者通过在 PGM 中简单地引入 Nesterov 加速而获得。

算法 3 PGM/APGM

input: 初始值 $\mathbf{x}_0 = \mathbf{z}_0$ 和步长 $\gamma > 0$

```

1: for  $t = 1, 2, \dots$  do
2:    $\mathbf{u}_t \leftarrow \mathbf{z}_{t-1} - \gamma \nabla g(\mathbf{z}_{t-1})$  ▷ 更多数据一致性
3:    $\mathbf{x}_t \leftarrow \text{prox}_{\gamma h}(\mathbf{u}_t)$  ▷ 更多正则化
4:    $\mathbf{z}_t \leftarrow \mathbf{x}_t + \frac{q_{t-1} - 1}{q_t}(\mathbf{x}_t - \mathbf{x}_{t-1})$ 
5: end for

```

基于 ADMM 的图像重建通过将逆问题 (Equation 20) 重新表述为等价的约束优化问题而获得。算法 4 总结了 ADMM 用于如下约束形式

$$\min_{\mathbf{x}, \mathbf{z}} g(\mathbf{z}) + h(\mathbf{x}) \quad \text{满足约束} \quad \mathbf{z} = \mathbf{x}. \quad (30)$$

该约束问题然后可通过构建增广 Lagrangian 函数 [39]²⁰ 与对偶变量 $\mathbf{s}$, 并以交替方式对 $\mathbf{x}$ 、 $\mathbf{z}$ 和 $\mathbf{s}$ 进行优化来处理。可以考虑其他类似的变量分裂策略以获得 ADMM 的不同变体 [40]。

算法 4 ADMM

input: 初始值 $\mathbf{x}_0$ 和惩罚参数 $\gamma > 0$

```

1: for  $t = 1, 2, 3, \dots$  do
2:    $\mathbf{u}_t \leftarrow \text{prox}_{\gamma g}(\mathbf{x}_{t-1} + \mathbf{z}_{t-1})$  ▷ 更多数据一致性
3:    $\mathbf{x}_t \leftarrow \text{prox}_{\gamma h}(\mathbf{u}_t - \mathbf{z}_{t-1})$  ▷ 更多正则化
4:    $\mathbf{z}_t \leftarrow \mathbf{z}_{t-1} + \mathbf{x}_t - \mathbf{u}_t$ 
5: end for

```

仔细考察 PGM/APGM 和 ADMM 可揭示这两类算法之间的若干相似性和差异性。两种算法均交替于通过分别应用算子 $\mathbf{I} - \gamma \nabla g$ 和 $\text{prox}_{\gamma g}$ 改善数据一致性, 以及通过应用算子 $\text{prox}_{\gamma h}$ 对图像施加先验知识。PGM/APGM 和 ADMM 的每次迭代复杂度可能因评估相应操作的难度而显著不同。例如, 对于 LS 项, 我们有

$$\nabla g(\mathbf{x}) = \mathbf{E}^H(\mathbf{E}\mathbf{x} - \mathbf{s}) \quad (32)$$

和

$$\begin{aligned} \text{prox}_{\gamma g}(\mathbf{x}) &= \arg \min_{\mathbf{z} \in \mathbb{C}^n} \left\{ \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2 + \frac{\gamma}{2} \|\mathbf{E}\mathbf{z} - \mathbf{s}\|_2^2 \right\} \\ &= (\mathbf{I} + \gamma \mathbf{E}^H \mathbf{E})^{-1} (\mathbf{x} + \gamma \mathbf{E}^H \mathbf{s}), \end{aligned} \quad (33)$$

¹⁹APGM 与 FISTA: 加速 PGM 也称快速迭代收缩/阈值算法 (Fast Iterative Shrinkage-Thresholding Algorithm, FISTA)。当 $q_t = 1$ 对所有迭代成立时, 算法对应传统 PGM; 当按 Equation 26 更新 $\{q_t\}$ 时, 得到 APGM/FISTA。APGM 通过在 PGM 中简单地引入 Nesterov 加速而获得, 其收敛速度从 PGM 的 $O(1/t)$ 提升至 $O(1/t^2)$ 。

²⁰增广 Lagrangian 函数: 对约束问题 $\min_{\mathbf{x}, \mathbf{z}} g(\mathbf{z}) + h(\mathbf{x})$ s.t. $\mathbf{z} = \mathbf{x}$, 其增广 Lagrangian 为

$$\mathcal{L}_\gamma(\mathbf{x}, \mathbf{z}, \mathbf{s}) = g(\mathbf{z}) + h(\mathbf{x}) + \mathbf{s}^T(\mathbf{x} - \mathbf{z}) + \frac{\gamma}{2} \|\mathbf{x} - \mathbf{z}\|_2^2, \quad (31)$$

其中 $\mathbf{s}$ 为对偶变量 (Lagrange 乘子), $\gamma > 0$ 为惩罚参数。ADMM 交替极小化 $\mathcal{L}_\gamma$ 关于 $\mathbf{z}$ 、 $\mathbf{x}$, 然后更新对偶变量 $\mathbf{s}$ 。算法 4 中的变量 $\mathbf{z}_t$ 实际上对应缩放后的对偶变量 $(\mathbf{s}/\gamma)$ 。

这通常用几次 CG 迭代求解²¹。

APGM 在凸函数上的收敛行为与 AGM 相同。为明确陈述，我们假设以下性质：

假设 3. 函数 g 连续可微且凸。此外，梯度 ∇g 是 Lipschitz 连续的，具有常数 $L > 0$ 。

假设 4. 函数 h 是正常、闭合且凸的。

假设 5. 函数 $f = g + h$ 具有有限最小值 $f^* = f(\mathbf{x}^*)$ 在某个 $\mathbf{x}^* \in \mathbb{C}^n$ 处取得，使得 $\|\mathbf{x}_0 - \mathbf{x}^*\|_2 \leq R$ 。

我们现在可以陈述以下优化中著名的结果（证明见 [33]）：

定理 2. 在假设 3-5 下，使用固定步长 $0 < \gamma \leq 1/L$ 运行 APGM $T \geq 1$ 次迭代。则该方法的迭代满足

$$f(\mathbf{x}_t) - f^* \leq \frac{2R^2}{\gamma(t+1)^2}. \quad (34)$$

因此，APGM 是 AGM 的推广，保持了相同的最优最坏情况收敛速度²²。

ADMM 的收敛性也在文献中得到了广泛研究 [34-36, 40]。为陈述一个结果，我们采用以下假设：

假设 6. 函数 g 和 h 均为正常、闭合且凸的。

假设 7. 强对偶性对 Equation 30 中的约束问题成立。

假设 6 简单地陈述了我们考虑的是一个凸优化问题。假设 7 的一个充分条件是 g 和 h 的定义域的内部具有公共向量（即它们的交集非空）。我们可以陈述以下经典结果（证明见 [40]）：

定理 3. 在假设 6 和 7 下，ADMM 迭代满足以下条件：

- 残差收敛：迭代趋近可行性

$$\lim_{t \rightarrow \infty} \|\mathbf{x}_t - \mathbf{z}_t\| = 0. \quad (35)$$

- 目标收敛：迭代的目标值趋近最优值

$$\lim_{t \rightarrow \infty} [g(\mathbf{z}_t) + h(\mathbf{x}_t)] = f^*. \quad (36)$$

在实践中，近端方法相比传统的基于次梯度或光滑化的技术提供了更快的收敛速度。APGM 和 ADMM 均显著快于 PGM，这在图 3.2 中 MRI 中 TV 正则化图像重建问题上得到了说明。注意 ADMM 的典型行为（在 [40] 中讨论），其中它在几十次迭代内收敛到中等精度，但收敛到高精度则较慢。ADMM 对中等精度的快速收敛使其适用于只需近似良好解的大规模图像重建。

²¹PGM 与 ADMM 的对比：（1）PGM 使用 ∇g （显式梯度步），而 ADMM 使用 $\text{prox}_{\gamma g}$ （隐式近端步）——后者更昂贵但可能更稳定；（2）对于光滑的 g ， ∇g 计算简单（一次 $\mathbf{E}$ 和 $\mathbf{E}^H$ 应用），而 $\text{prox}_{\gamma g}$ 需要求解一个线性系统（通常用 CG 迭代）；（3）ADMM 通常在少量迭代内达到中等精度，但高精度收敛慢；PGM/APGM 的收敛行为更为均匀。

²²APGM 与投影梯度法：注意，当近端算子对应于投影时，APGM 退化为投影梯度法的加速变体。同样地，当 h 光滑时， $\text{prox}_{\gamma h}$ 近似于 $\mathbf{I} - \gamma \nabla h$ ，APGM 退化为 AGM。

3.3 原始-对偶算法

原始-对偶算法也可用于求解 MRI 中出现的各种优化问题。一个典型的原始目标函数可写为

$$\min_{\mathbf{x}} g(\mathbf{E}\mathbf{x}) + h(\mathbf{x}) \quad (\text{原始问题}), \quad (37)$$

其中 $g(\mathbf{E}\mathbf{x})$ 是数据保真项, $h(\mathbf{x})$ 是正则化项。Chambolle-Pock (CP) 算法 [41] 是一种一阶原始-对偶方法, 求解以下鞍点问题²³:

$$\min_{\mathbf{x}} \max_{\mathbf{v}} \langle \mathbf{E}\mathbf{x}, \mathbf{v} \rangle + h(\mathbf{x}) - g^*(\mathbf{v}) \quad (\text{原始-对偶问题}), \quad (38)$$

其中 $g^*(\mathbf{x})$ 是 $g(\mathbf{x})$ 的凸共轭 [9]。转向原始-对偶方法而非求解原始函数的理由直接在于 $g(\mathbf{E}\mathbf{x})$ 的近端算子的非平凡表述。我们可以容易地表述 $g^*(\mathbf{x})$ 和 $h(\mathbf{x})$ 的近端算子。我们交替对 $\mathbf{x}$ 和 $\mathbf{v}$ 执行近端梯度下降以根据算法 5 求解 Equation 38 中的优化问题。多年来, 已提出多种原始-对偶方法的变体以求解光滑和非光滑优化问题 [41-48]。

$g(\mathbf{E}\mathbf{x})$ 可以是非光滑函数, 如 hinge 损失 [49]、广义 hinge 损失 [50]、绝对损失 [51] 或 ϵ -不敏感损失 [52]。 $h(\mathbf{x})$ 可以是非光滑正则化器, 如 lasso [53]、组 lasso [54]、稀疏组 lasso [55]、排他 lasso [56]、 $\ell_{1,\infty}$ 正则化器 [57] 或迹范数正则化器 [58]。

算法 5 原始-对偶方法 [41, 42]

input: 初始值 $\mathbf{x}_0$ 、 $\bar{\mathbf{x}}_0$ 、 $\mathbf{v}_0$

1: $t \leftarrow 0$

2: 选择步长 $\sigma > 0$ 和 $\tau > 0$, 使得 $\sigma\tau L^2 < 1$, 其中 $L = \|\mathbf{E}\|$ 为诱导范数, 以及 $\theta \in [0, 1]$

3: **repeat**

4: $\mathbf{v}_{t+1} \leftarrow \text{prox}_{\sigma g^*}(\mathbf{v}_t + \sigma \mathbf{E}\bar{\mathbf{x}}_t)$

▷ 对偶近端

5: $\mathbf{x}_{t+1} \leftarrow \text{prox}_{\tau h}(\mathbf{x}_t - \tau \mathbf{E}^* \mathbf{v}_{t+1})$

▷ 原始近端

6: $\bar{\mathbf{x}}_{t+1} \leftarrow \mathbf{x}_{t+1} + \theta(\mathbf{x}_{t+1} - \mathbf{x}_t)$

▷ 外推

7: $t \leftarrow t + 1$

8: **until** 满足收敛/终止条件

3.4 基于随机梯度的方法

随机梯度下降 (Stochastic Gradient Descent, SGD) 方法的随机版本随着神经网络的兴起而变得流行。近年来, SGD 方法在求解各种非凸优化问题方面取得了极大的成功。多年来, 已提出 GD 和 SGD 方法的多种变体以确保更好的收敛性。这些方法包括 Nesterov 加速梯度 (Nesterov Accelerated Gradient, NAG) [59]、Adagrad [60]、RMSprop [61]、Adadelta [62]、自适应矩估计 (Adaptive Moment Estimation, ADAM) [63] 和 Nesterov 加速自适应矩估计 (Nesterov-Accelerated Adaptive Moment Estimation, NADAM) [64]。

²³原始-对偶与凸共轭: $g^*(\mathbf{v}) = \sup_{\mathbf{u}} \{\langle \mathbf{u}, \mathbf{v} \rangle - g(\mathbf{u})\}$ 是 g 的凸共轭 (或 Fenchel-Legendre 变换)。鞍点问题 $\min_{\mathbf{x}} \max_{\mathbf{v}} \langle \mathbf{E}\mathbf{x}, \mathbf{v} \rangle + h(\mathbf{x}) - g^*(\mathbf{v})$ 与原始问题等价, 因为 $\max_{\mathbf{v}} \{\langle \mathbf{E}\mathbf{x}, \mathbf{v} \rangle - g^*(\mathbf{v})\} = g(\mathbf{E}\mathbf{x})$ 。原始-对偶方法的关键动机在于: 即使 $g(\mathbf{E}\mathbf{x})$ 的近端算子难以计算 (由于 $\mathbf{E}$ 的存在), $g^*(\mathbf{v})$ 的近端算子通常具有闭合形式。

Nesterov 加速梯度 (NAG) 将动量项纳入 GD 更新步骤。随着 GD 迭代接近局部极小值, 更新通常逐渐变小, 否则我们将从一个局部极小值附近跳到另一个。为确保这一点, 引入了动量项。动量项对梯度指向相同方向的参数增加更新量, 对梯度改变方向的参数减少更新量。Adagrad 基于特征的出现频率自适应调整参数的学习率。Adagrad 对不常出现的特征具有递减的学习率。RMSprop 和 Adadelta 均被开发以解决 Adagrad 学习率递减的问题。Adam 使用梯度的一阶矩和二阶矩进行 GD 更新。NADAM 通过修改动量项将 Adam 和 NAG 相结合²⁴。

4 小结

本章回顾了 MRI 图像重建背景下若干广泛使用的优化策略。这类算法所需的关键性质是利用关于未知图像 $\mathbf{x}$ 的有用先验信息的能力。我们讨论了处理光滑和非光滑正则化器的算法。

从最小二乘重建出发, 当 $\mathbf{E}$ 良态且全采样时, 闭合解可通过 Moore-Penrose 广义逆直接获得。在加速采样的欠定情形下, 必须借助迭代方法 (GD、CG) 求解。GD 的收敛条件取决于步长 γ 与 $\mathbf{E}^H \mathbf{E}$ 最大特征值的关系 (Equation 15), 而 CG 作为 Krylov 子空间方法可在至多 n 次迭代内精确求解线性系统。

随后, 我们将 MR 重建推广为一般正则化优化问题 $\min_{\mathbf{x}} g(\mathbf{x}) + h(\mathbf{x})$, 按照 h 的光滑性分为两类算法族:

1. **光滑优化:** 当 h 光滑时 (如 Tikhonov 正则化), 可使用 AGM 及其变体, 通过 Nesterov 动量外推达到最优 $O(1/t^2)$ 收敛速度 (定理 1)。
2. **非光滑优化:** 当 h 不可微时 (如 TV、 ℓ_1 正则化), 近端算法成为标准工具。PGM 通过显式梯度步 + 近端步交替工作, 其加速版本 APGM/FISTA 同样达到 $O(1/t^2)$ 速度 (定理 2)。ADMM 通过变量分裂将原问题转化为约束问题, 利用增广 Lagrangian 交替极小化, 在少量迭代内可达到中等精度 (定理 3)。原始-对偶 (Chambolle-Pock) 方法通过鞍点表述同时更新原始和对偶变量, 对具有复杂线性算子的非光滑项 (如 $g(\mathbf{E}\mathbf{x})$) 特别有效。

最后, 基于随机梯度的方法 (SGD 及其变体 Adam、NADAM 等) 结合了动量和自适应学习率, 在深度学习驱动的 MR 重建中发挥着核心作用。这些方法的详细应用将在后续章节中展开。

²⁴SGD 方法总结: (1) SGD ——最基本的随机优化方法; (2) NAG ——在 SGD 中加入 Nesterov 动量, 使更新沿更平滑的轨迹行进; (3) Adagrad ——自适应学习率, 参数相关的学习率反比于历史梯度平方和的平方根; (4) RMSprop/Adadelta ——用指数移动平均替代 Adagrad 中的累加求和, 解决学习率单调递减问题; (5) Adam ——结合动量 (一阶矩估计) 和自适应学习率 (二阶矩估计), 是目前最广泛使用的优化器之一; (6) NADAM ——在 Adam 中融入 Nesterov 加速, 将动量项替换为“向前看”的 Nesterov 形式。这些方法在基于深度学习的 MR 重建 (如变分网络、深度展开网络) 中被广泛应用。

A 物理量符号及含义

符号	含义	单位/类型
$\mathbf{s}$	向量化 k 空间数据	$\mathbb{C}^m$
$\mathbf{x}$	向量化待重建图像	$\mathbb{C}^n$
$\hat{\mathbf{x}}$	重建图像估计	$\mathbb{C}^n$
$\mathbf{F}$	二维 Fourier 变换矩阵	$\mathbb{C}^{n \times n}$
$\mathbf{B}$	k 空间采样矩阵	$\{0, 1\}^{p \times n}$
$\mathbf{C}_c$	第 c 个线圈的灵敏度对角矩阵	$\mathbb{C}^{n \times n}$
$\mathbf{E}$	测量算子（正演模型矩阵）	$\mathbb{C}^{m \times n}$
ϵ	加性 Gaussian 噪声	$\mathbb{C}^m$
m	k 空间测量值总数 ($= pT$)	$\mathbb{N}$
n	图像像素/体素总数	$\mathbb{N}$
p	每线圈 k 空间采样点数	$\mathbb{N}$
T	接收线圈总数	$\mathbb{N}$
$\mathbf{E}^H$	$\mathbf{E}$ 的 Hermitian 转置	—
γ_t	第 t 次迭代的步长	$\mathbb{R}_+$
$\lambda_{\max}(\cdot)$	矩阵的最大特征值	—
$\mathbf{I}$	单位矩阵	无量纲
$\mathcal{A}(\cdot)$	CG 中的对称正定系统算子	—
$\mathbf{r}_t$	第 t 次迭代的残差向量	$\mathbb{C}^n$
$\mathbf{p}_t$	第 t 次迭代的搜索方向	$\mathbb{C}^n$
α_t	CG 中的步长参数	$\mathbb{R}$
β_t	CG 中的共轭方向参数	$\mathbb{R}$
$g(\mathbf{x})$	数据保真项	$\mathbb{R}$
$h(\mathbf{x})$	正则化器（先验项）	$\mathbb{R}$
$f(\mathbf{x})$	总目标函数 $= g(\mathbf{x}) + h(\mathbf{x})$	$\mathbb{R}$
λ	正则化参数	$\mathbb{R}_+$
Φ	稀疏变换矩阵	—
∇f	标量函数 f 的梯度	$\mathbb{C}^n$
$\nabla^2 f$	标量函数 f 的 Hessian 矩阵	$\mathbb{C}^{n \times n}$
L	Lipschitz 常数	$\mathbb{R}_+$
q_t	Nesterov 加速的过度松弛参数	$\mathbb{R}$
$\text{prox}_{\lambda h}(\cdot)$	函数 λh 的近端算子	—
$\mathbf{z}_t$	PGM/APGM/ADMM 中的辅助变量	$\mathbb{C}^n$
$\mathbf{u}_t$	算法中的中间变量	$\mathbb{C}^n$
$g^*(\cdot)$	$g(\cdot)$ 的凸共轭（Fenchel-Legendre 变换）	—
σ, τ	原始-对偶算法中的步长参数	$\mathbb{R}_+$
$L = \ \mathbf{E}\ $	$\mathbf{E}$ 的诱导矩阵范数（谱范数）	—
θ	原始-对偶算法中的外推参数	$[0, 1]$
$\langle \cdot, \cdot \rangle$	内积	—
f^*	f 的全局最小值	$\mathbb{R}$
R	初始点到最优解的距离上界	$\mathbb{R}_+$
$1_{\mathcal{X}}(\cdot)$	集合 $\mathcal{X}$ 的示性函数	—

B 术语中英文及缩写索引

下表按术语在正文中首次出现的先后顺序排列，页码为其首次出现位置。

中文术语	英文全称	缩写	页码
加性白 Gaussian 噪声	Additive White Gaussian Noise	AWGN	2
最大似然估计	Maximum Likelihood Estimation	MLE	2
最小二乘	Least Squares	LS	3
梯度下降	Gradient Descent	GD	3
共轭梯度	Conjugate Gradient	CG	5
最大后验概率	Maximum a Posteriori	MAP	6
加速梯度法	Accelerated Gradient Method	AGM	7
优化梯度法	Optimized Gradient Method	OGM	8
全变分	Total Variation	TV	8
总广义变分	Total Generalized Variation	TGV	8
近端梯度法	Proximal Gradient Method	PGM	8
交替方向乘法	Alternating Direction Method of Multipliers	ADMM	8
加速近端梯度法	Accelerated Proximal Gradient Method	APGM	9
快速迭代收缩/阈值算法	Fast Iterative Shrinkage-Thresholding Algorithm	FISTA	9
Chambolle-Pock 算法	Chambolle-Pock	CP	11
随机梯度下降	Stochastic Gradient Descent	SGD	11
Nesterov 加速梯度	Nesterov Accelerated Gradient	NAG	11
自适应矩估计	Adaptive Moment Estimation	ADAM	11
Nesterov 加速自适应矩估计	Nesterov-Accelerated Adaptive Moment Estimation	NADAM	11