

MR 重建中的优化算法

甘嘉程

2026 年 8-9 月

摘要

本报告基于《Advances in Magnetic Resonance Technology and Applications》第三章内容，系统梳理了 MR 图像重建中的优化算法。报告从 MR 正向模型的基本形式出发，首先讨论了最小二乘（Least Squares）重建的闭合解与迭代求解方法，包括梯度下降法（Gradient Descent）和共轭梯度法（Conjugate Gradient）的详细推导、收敛条件以及算法伪代码。随后，报告将 MR 重建形式化为正则化优化问题 $\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \{g(\mathbf{x}) + h(\mathbf{x})\}$ ，并分别讨论了光滑优化方法（Tikhonov 正则化、加速梯度法 AGM 及其 $O(1/t^2)$ 收敛性）和非光滑优化方法（近端梯度法 PGM/APGM/FISTA、交替方向乘子法 ADMM、原始-对偶 Chambolle-Pock 算法）。报告详细推导了各类算法的迭代格式、近端算子的计算、收敛性定理，并通过算法伪代码加以说明。最后简要介绍了随机梯度方法（Stochastic Gradient Descent、Adaptive Moment Estimation、Nesterov-Accelerated Adaptive Moment Estimation，缩写 SGD、Adam、NADAM）等在 MR 重建中的应用前景。本报告的特点是在保持原文数学推导和算法完整性的基础上，将其翻译为中文并保持所有公式格式与原文一致。

本章从优化理论的视角出发，系统阐述了 MR 图像重建中各类迭代算法的数学原理和收敛性质，涵盖光滑与非光滑目标函数、一阶加速方法、算子分裂技术以及原始-对偶框架，为理解现代 MR 重建算法的设计思想和实现细节提供了完整的数学基础。

1 MR 重建模型回顾与优化算法概述

首先来简要回顾第二章论述的 MR 重建问题的数学模型。MR 数据采集在 k 空间中进行，其对应于图像的 Fourier 变换。当全采样时， k 空间数据 $\mathbf{s} \in \mathbb{C}^p$ 与图像数据 $\mathbf{x} \in \mathbb{C}^n$ 间的正向模型

$$\mathbf{s} = \mathbf{F}\mathbf{x} \quad (1)$$

其中 $\mathbf{F}$ 表示二维 Fourier 变换矩阵，其元素 $F_{kr} = \exp(-i2\pi \mathbf{k}_k^T \mathbf{r}_r)$ ， $\mathbf{k}_k \in \mathbb{R}^2$ 表示第 k 个 k 空间采样点的位置（ $\mathbf{k}_k^T$ 为其转置）， $\mathbf{r}_r \in \mathbb{R}^2$ 表示第 r 个像素的空间坐标。

在并行成像中，引入线圈空间灵敏度编码矩阵 $\mathbf{C}_c$ ，其是一个块对角矩阵，其对角线块为第 c

个线圈的空间灵敏度图。第 c 个线圈的全采样 k 空间数据为

$$\mathbf{s}_c = \mathbf{F}\mathbf{C}_c\mathbf{x} \quad (2)$$

当欠采样时, $p < n$, 设 $T \geq 1$ 为接收线圈数量, 则

$$\mathbf{s}_c = \mathbf{B}\mathbf{F}\mathbf{C}_c\mathbf{x} + \boldsymbol{\epsilon}_c \quad (3)$$

其中 $\mathbf{B} \in \mathbb{R}^{p \times n}$ 为采样矩阵, $\boldsymbol{\epsilon}_c \in \mathbb{C}^p$ 为线圈测量噪声。通过将所有线圈的测量值拼接为采样向量 $\mathbf{s} = (\mathbf{s}_1, \dots, \mathbf{s}_c, \dots, \mathbf{s}_T)$, 我们得到正向模型

$$\boxed{\mathbf{s} = \mathbf{E}\mathbf{x} + \boldsymbol{\epsilon}} \quad (4)$$

其中 $\mathbf{E} = \mathbf{B}\mathbf{F}\mathbf{C}_c \in \mathbb{C}^{T \times p \times n = m \times n}$ 位编码矩阵¹, $\boldsymbol{\epsilon} \in \mathbb{C}^m$ 为总测量噪声, 通常假设为加性白 Gaussian 噪声 (Additive White Gaussian Noise, AWGN)。

本章将讨论若干 MR 图像重建的优化策略。第二章论述了 MR 图像重建的数学基础是求解逆问题², 其中采集的 MR 数据 $\mathbf{s}$ 被图像先验知识所补全。不同的优化方法基于目标函数 (即数据保真项和正则化项) 的性质而产生。此外, 现代优化方法分为基于模型的重建方法和利用数据驱动先验的方法。在本章中, 将讨论不同迭代优化算法收敛性与收敛速度。

2 最小二乘重建

考虑Equation 4即从含噪测量值 $\mathbf{s} \in \mathbb{C}^m$ 重建图像 $\mathbf{x} \in \mathbb{C}^n$ 的逆问题。当 $\mathbf{E}$ 为良态矩阵³且 $m \geq n$ 时, 使用最大似然估计 (Maximum Likelihood Estimation, MLE) 重建 $\mathbf{x}$ 。对于 AWGN 模

¹编码矩阵 $\mathbf{E}$ 无需为显式矩阵, 而是可以作为一个函数, 依次计算线圈灵敏度与图像像素乘积、Fourier 编码和子采样。

²在 MR 重建中, 逆问题的解通常通过优化一个目标函数来获得, 根据目标函数的性质 (如光滑性、凸性等), 产生了不同的优化方法。特别地, 在正则化问题中, 目标函数由数据保真项 (量化与测量数据的一致性) 和正则化项 (编码先验知识) 组成, 这种情况是普遍存在的 (见第二章)。

³良态矩阵 (Well-conditioned Matrix): 条件数 $\kappa(\mathbf{E}) = \|\mathbf{E}\| \cdot \|\mathbf{E}^\dagger\|$ 较小的矩阵。良态矩阵的测量噪声或近似误差经求解过程放大有限; 反之, 病态矩阵 (Ill-conditioned Matrix) 会放大微扰对解的影响。在全采样 (或过采样) 条件下, 良态条件保证 $\mathbf{E}$ 列满秩, 从而 $\mathbf{E}^H\mathbf{E}$ 正定可逆, Equation 5中的闭合解存在、唯一且数值稳定 (满足三个 Hadamard 条件), 确保可以使用 MLE 求解逆问题。

型，可由 MLE 推导⁴具有闭合解的最小二乘（Least Squares, LS）问题⁵⁶

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} f(\mathbf{x}) = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 \quad (5)$$

其中 $f(\mathbf{x}) = \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2$ 称为 LS 问题的目标函数。

接下来讨论 Equation 5 的求解。由于

$$\mathbf{E}^H \mathbf{E} = \sum_{c=1}^T \mathbf{C}_c^H \mathbf{F}^H \mathbf{B}^T \mathbf{B} \mathbf{F} \mathbf{C}_c \quad (6)$$

当问题维数（即 $\mathbf{E}$ 规模）很大时，Equation 6 的计算和储存具有较高复杂度。若所有采样线圈的数据均为 k-空间全采样，即 $\mathbf{B} \in \mathbb{R}^{n \times n}$ 且 $m = Tn$ ，Equation 6 可简化为对角矩阵

$$\mathbf{E}^H \mathbf{E} = \sum_{c=1}^T \mathbf{C}_c^H \mathbf{C}_c \Rightarrow \hat{\mathbf{x}} = (\mathbf{E}^H \mathbf{E})^{-1} (\mathbf{E}^H \mathbf{s}) = \left(\sum_{c=1}^T \mathbf{C}_c^H \mathbf{C}_c \right)^{-1} \sum_{c=1}^T \mathbf{C}_c^H \mathbf{F}^H \mathbf{s}_c \quad (7)$$

此时 $\hat{\mathbf{x}}$ 可以写出显式解需要满足 $\mathbf{E}^H \mathbf{E}$ 可逆，而全采样（或过采样）满足了这一条件。若使用欠采样并行采集，即 $\mathbf{B} \in \mathbb{R}^{p \times n}$ 且 $p < n$ ，则无法显式写出 $\mathbf{E}^H \mathbf{E}$ 及其逆，故也无法写出 $\hat{\mathbf{x}}$ 的显式解，需用梯度下降法或共轭梯度法等迭代方法求解 Equation 5 中的 LS 问题。接下来我们将逐一讨论。

2.1 梯度下降法

梯度下降（Gradient Descent, GD）法求解 LS 问题的基本原理是：在当前估计处计算目标函数的梯度，并以适当的步长沿梯度的负方向迭代更新估计。在这个过程中，GD 通过迭代尝试找到满足收敛条件的最小的 $\hat{\mathbf{x}}$ ，而负梯度的使用正是为了不断向下放缩 $\mathbf{x}_i$ 。

具体来说，对 Equation 5 中的 LS 目标函数 Taylor 展开到一阶

$$f(\mathbf{x}_{t-1} - \gamma \hat{\mathbf{e}}) \approx f(\mathbf{x}_{t-1}) - \gamma \hat{\mathbf{e}}^H \nabla f(\mathbf{x}_{t-1}) \quad (8)$$

其中 $\hat{\mathbf{e}}$ 为单位向量。代入其梯度 $\nabla f(\mathbf{x}) = \mathbf{E}^H (\mathbf{E}\mathbf{x} - \mathbf{s})$ ⁷ 可得，在第 t 次 GD 迭代中，当前估计 $\mathbf{x}_{t-1}$ 沿负梯度方向更新的估计

$$\mathbf{x}_t = \mathbf{x}_{t-1} - \gamma_t \nabla f(\mathbf{x}_{t-1}) = \mathbf{x}_{t-1} - \gamma_t \mathbf{E}^H (\mathbf{E}\mathbf{x}_{t-1} - \mathbf{s}) \quad (9)$$

⁴推导过程见第二章。

⁵勘误：原文 p.61(3.4) 出现 $\frac{1}{2}$ 因子，与第二章 (28) 式系数不同。实际上，对图像的估计 $\hat{\mathbf{x}}$ 取目标函数最小值点，而目标函数整体缩放不影响最小值点，故两式的解相同。而本章加入 $\frac{1}{2}$ 因子后，目标函数的梯度为 $\mathbf{E}^H (\mathbf{E}\mathbf{x} - \mathbf{s})$ （推导过程见第二章），与梯度下降（Equation 9）更新方向一致。而在 GD 迭代中，目标函数缩放因子的差异被步长 γ 吸收：本章收敛条件 Equation 15 包含了缩放因子的倒数，若按第二章的写法则为 $0 < \gamma \leq 1/\lambda_{\max}(\mathbf{E}^H \mathbf{E})$ 。

⁶勘误：最小二乘的目标函数 $\frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2$ 为实值函数，本章所有梯度结果都应取实部。在本文中沿用了原文的表述，省略了取实部。

⁷推导过程见第二章。

其中 $\gamma_t > 0$ 为步长，可在每次迭代时调整或保持固定。GD 的收敛性和收敛速度取决于步长选择，步长过大可能导致发散，步长过小则收敛缓慢。

接下来讨论 GD 迭代解 Equation 9 收敛于 LS 问题 Equation 5 的解的条件。假设 GD 的初值为零向量 $\mathbf{x}_0 = \mathbf{0}$ ，且对所有 t 有 $\gamma_t = \gamma$ ，则递归写出

$$\mathbf{x}_t = (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}) \mathbf{x}_{t-1} + \gamma \mathbf{E}^H \mathbf{s} = \gamma \sum_{k=0}^{t-1} (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E})^k \mathbf{E}^H \mathbf{s} \quad (10)$$

由于当谱范数 $\|\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}\|_2 < 1$ 时⁸，矩阵几何级数 $\sum_k (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E})^k$ 收敛于 $(\gamma \mathbf{E}^H \mathbf{E})^{-1}$ ，此时

$$\lim_{t \rightarrow \infty} \mathbf{x}_t = \gamma (\gamma \mathbf{E}^H \mathbf{E})^{-1} \mathbf{E}^H \mathbf{s} = (\mathbf{E}^H \mathbf{E})^{-1} \mathbf{E}^H \mathbf{s} \quad (13)$$

即 GD 收敛于 Equation 5 的 LS 解。

记 Hermitian 正定矩阵 $\mathbf{E}^H \mathbf{E}$ 的特征值为 $0 < \lambda_1 \leq \dots \leq \lambda_n = \lambda_{\max}(\mathbf{E}^H \mathbf{E})$ ，则 $\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}$ 的特征值为 $1 - \gamma \lambda_i$ ($i = 1, \dots, n$)。对 Hermitian 矩阵⁹，收敛条件

$$\|\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}\|_2 = \max |\lambda_i (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E})| = \max |1 - \gamma \lambda_i| < 1 \quad (14)$$

要求所有特征值满足 $|1 - \gamma \lambda_i| < 1$ ，则¹⁰

$$0 < \gamma \lambda_i < 2 \quad \Rightarrow \quad \gamma < \frac{2}{\lambda_i}, \quad \forall i \quad \Leftrightarrow \quad \boxed{0 < \gamma < \frac{2}{\lambda_{\max}(\mathbf{E}^H \mathbf{E})}} \quad (15)$$

需要强调：1) 受 $\mathbf{E}$ 规模和 γ 的影响，GD 法可能不收敛或收敛非常缓慢；2) 上述讨论基于 GD 迭代解初值的选择，因此选定不同初值也可能影响 GD 法的收敛情况。

⁸谱范数 (Spectral Norm)：矩阵 $\mathbf{A}$ 的谱范数由向量 ℓ_2 范数诱导，定义为

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|_2}{\|\mathbf{x}\|_2} \quad (11)$$

表示矩阵作用于向量后放大向量长度的最大倍数。 $\mathbf{A}$ 的谱范数等于其最大奇异值

$$\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^H \mathbf{A})} \quad (12)$$

总的来说，向量范数衡量向量自身的长度（如 ℓ_1 范数为分量绝对值之和， ℓ_2 范数为欧氏长度），而矩阵范数衡量矩阵对向量的拉伸能力。

⁹对 Hermitian 矩阵 $\mathbf{A}$ ，谱范数等于特征值绝对值中的最大值，即 $\|\mathbf{A}\|_2 = \max |\lambda_i(\mathbf{A})|$ 。利用该性质可将范数条件转化为特征值条件 $|1 - \gamma \lambda_i| < 1$ 。

¹⁰勘误：p.62(3.8) 对 γ 取值范围上界取等。事实上，当 $\gamma = 2/\lambda_{\max}$ 时， $1 - \gamma \lambda_{\max} = -1$ ，谱范数恰为 1，几何级数不收敛。因此，本文中 γ 取值范围为严格开区间。

2.2 线性共轭梯度法

共轭梯度（Conjugate Gradient, CG）法适用于对称正定矩阵，其核心思路是：在每次迭代中，沿一个与所有先前迭代更新方向共轭的方向更新估计。这种迭代思路确保 CG 法在求解具有 n 个方程的方程组时在最多 n 次迭代内收敛。

设算符 $\mathcal{A}$ 由一个 $n \times n$ 对称正定矩阵定义，给定线性系统

$$\mathbf{y} = \mathcal{A}(\mathbf{x}) \quad (16)$$

如Equation 5给出的正规方程

$$\underbrace{\mathbf{E}^H \mathbf{s}}_{\mathbf{y}} = \underbrace{\mathbf{E}^H \mathbf{E} \mathbf{x}}_{\mathcal{A}(\mathbf{x})} \quad (17)$$

可用 CG 法求解。CG 法（Algorithm 1）的主要结构包括：1）应用一次算符 $\mathcal{A}$ 迭代更新残差 $\mathbf{r}_t$ ；2）步长 α_t 通过最小化残差 $\|\mathbf{r}_t\|_2^2$ 在搜索方向 $\mathbf{p}_t$ 上的二次型来解析计算，即

$$\alpha_t = \frac{\|\mathbf{r}_t\|_2^2}{\mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t)} \quad (18)$$

这等价于在当前搜索方向上的一维线搜索¹¹；3） β_t 确保新搜索方向 $\mathbf{p}_{t+1}$ 与所有先前方向关于 $\mathcal{A}$ 共轭，即 $\mathbf{p}_i^T \mathcal{A}(\mathbf{p}_j) = 0$ ($i \neq j$)。

2.3 非线性共轭梯度法

线性 CG 法可以视作极小化二次函数 $f(\mathbf{x}) = \|\mathcal{A}(\mathbf{x}) - \mathbf{y}\|_2^2$ ，而非线性 CG 法可以极小化任何可计算梯度的连续函数 $f(\mathbf{x})$ 。在非线性 CG 法中， β 的计算公式由 Fletcher-Reeves (FR)、Polak-

¹¹线搜索（Line Search）：在沿搜索方向 $\mathbf{p}_t$ 确定步长 α_t 的过程中，把多维极小化约化为直线 $\{\mathbf{x}_t + \alpha \mathbf{p}_t : \alpha \in \mathbb{R}\}$ 上的一维优化

$$\min_{\alpha} f(\mathbf{x}_t + \alpha \mathbf{p}_t) \quad (19)$$

在线性 CG 中，线搜索有解析解。设目标函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathcal{A}(\mathbf{x}) - \mathbf{y}^T \mathbf{x}$ （与 $\|\mathcal{A}(\mathbf{x}) - \mathbf{y}\|_2^2$ 极小点相同的等价二次型），令

$$\frac{d}{d\alpha} f(\mathbf{x}_t + \alpha \mathbf{p}_t) = \mathbf{p}_t^T [\mathcal{A}(\mathbf{x}_t) - \mathbf{y}] + \alpha \mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t) = 0 \quad (20)$$

$$\Rightarrow \alpha_t = \frac{\mathbf{p}_t^T (\mathbf{y} - \mathcal{A}(\mathbf{x}_t))}{\mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t)} \quad (21)$$

约定残差 $\mathbf{r}_t = \mathbf{y} - \mathcal{A}(\mathbf{x}_t)$ 并利用正交性 $\mathbf{p}_t^T \mathbf{r}_t = \|\mathbf{r}_t\|_2^2$ ，可得步长公式Equation 18。而在非线性 CG 中，线搜索一般无解析解，需使用迭代线搜索方法。

算法 1 求解 $\mathbf{y} = \mathcal{A}(\mathbf{x})$ 的线性共轭梯度法

```
1: input: 初值  $\mathbf{x}_0$  和残差  $\mathbf{r}_0 = \mathcal{A}(\mathbf{x}_0) - \mathbf{y}$ 
2:  $t \leftarrow 0$ 
3:  $\mathbf{p}_0 \leftarrow \mathbf{r}_0$ 
4: repeat
5:    $\alpha_t \leftarrow \frac{\|\mathbf{r}_t\|_2^2}{\mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t)}$  ▷ 线搜索
6:    $\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t + \alpha_t \mathbf{p}_t$ 
7:    $\mathbf{r}_{t+1} \leftarrow \mathbf{r}_t - \alpha_t \mathcal{A}(\mathbf{p}_t)$  ▷ 更新残差
8:   if  $\|\mathbf{r}_t\|_2^2 \leq \text{阈值}$  then
9:     break
10:  end if
11:   $\beta_t \leftarrow \frac{\|\mathbf{r}_{t+1}\|_2^2}{\|\mathbf{r}_t\|_2^2}$  ▷ 共轭搜索系数
12:   $\mathbf{p}_{t+1} \leftarrow \mathbf{r}_{t+1} + \beta_t \mathbf{p}_t$ 
13:   $t \leftarrow t + 1$ 
14: until 满足收敛/终止条件
```

Ribière (PR)、Hestenes-Stiefel (HS) 和 Dai-Yuan (DY) 给出

$$\beta_{t+1}^{\text{FR}} = \frac{\mathbf{r}_{t+1}^T \mathbf{r}_{t+1}}{\mathbf{r}_t^T \mathbf{r}_t} \quad (22)$$

$$\beta_{t+1}^{\text{PR}} = \frac{\mathbf{r}_{t+1}^T (\mathbf{r}_{t+1} - \mathbf{r}_t)}{\mathbf{r}_t^T \mathbf{r}_t} \quad (23)$$

$$\beta_{t+1}^{\text{HS}} = \frac{\mathbf{r}_{t+1}^T (\mathbf{r}_{t+1} - \mathbf{r}_t)}{-\mathbf{p}_t^T (\mathbf{r}_{t+1} - \mathbf{r}_t)} \quad (24)$$

$$\beta_{t+1}^{\text{DY}} = \frac{\mathbf{r}_{t+1}^T \mathbf{r}_{t+1}}{-\mathbf{p}_t^T (\mathbf{r}_{t+1} - \mathbf{r}_t)} \quad (25)$$

非线性 CG 法的伪代码见 [Algorithm 2](#)。需要指出，一般函数 f 可能具有许多局部极小值，无法保证 CG 收敛到全局极小值。

算法 2 极小化连续函数 $f(\mathbf{x})$ 的非线性共轭梯度法

```
1: input: 初始值  $\mathbf{x}_0$ 
2:  $t \leftarrow 0$ 
3:  $\mathbf{p}_0 \leftarrow \mathbf{r}_0 \leftarrow -\nabla f(\mathbf{x}_0)$ 
4: repeat
5:    $\alpha_t \leftarrow \arg \min_{\alpha_t} f(\mathbf{x}_t + \alpha_t \mathbf{p}_t)$  ▷ 线搜索
6:    $\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t + \alpha_t \mathbf{p}_t$ 
7:    $\mathbf{r}_{t+1} \leftarrow -\nabla f(\mathbf{x}_{t+1})$  ▷ 更新参差
8:   if  $\|\mathbf{r}_t\|_2^2 \leq \text{阈值}$  then
9:     break
10:  end if
11:   $\beta_{t+1} \leftarrow \beta_{t+1}$  ▷ 使用 FR、PR、HS、DY 等公式，确定共轭搜索系数
12:   $\mathbf{p}_{t+1} \leftarrow \mathbf{r}_{t+1} + \beta_{t+1} \mathbf{p}_t$ 
13:   $t \leftarrow t + 1$ 
14: until 满足收敛/终止条件
```

3 基于模型的重建

当欠采样（即 $m < n$ ）时，将欠定逆问题表述为正则化问题

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} f(\mathbf{x}) = \arg \min_{\mathbf{x}} \{g(\mathbf{x}) + h(\mathbf{x})\} \quad (26)$$

其中 g 是数据保真项， h 是编码先验知识的正则化项。本节讨论正则化问题 Equation 26 的求解优化方法。subsection 3.1 讨论可微目标函数 f 的光滑优化方法，subsection 3.2 考虑适用于不可微正则化项的非光滑优化方法。

3.1 光滑优化

光滑优化的一种方法是基于 Tikhonov 正则化（ ℓ_2 范数正则化）。第二章指出，任意线性矩阵 $\mathbf{L}$ 均可放入 Tikhonov 正则化项，即

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \{\|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 + \lambda\|\mathbf{L}\mathbf{x} - \mathbf{x}^0\|_2^2\} \quad (27)$$

可以得到 $\mathbf{x}$ 的显式解析解

$$\hat{\mathbf{x}} = (\text{Re}[\mathbf{E}^H \mathbf{E}] + \lambda \text{Re}[\mathbf{L}^H \mathbf{L}])^{-1} (\text{Re}[\mathbf{E}^H \mathbf{s}] + \lambda \text{Re}[\mathbf{L}^H] \mathbf{x}^0) \quad (28)$$

本节取 $\mathbf{L}$ 为稀疏变换 Φ ，设无参考图像先验即 $\mathbf{x}^0 = \mathbf{0}$ ，则 Equation 26 中的 g 和 h 分别为¹²¹³

$$g(\mathbf{x}) = \frac{1}{2}\|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 \quad h(\mathbf{x}) = \frac{\lambda}{2}\|\Phi\mathbf{x}\|_2^2 \quad (29)$$

$$\Rightarrow \boxed{\hat{\mathbf{x}} = (\mathbf{E}^H \mathbf{E} + \lambda \Phi^H \Phi)^{-1} (\mathbf{E}^H \mathbf{s})} \quad (30)$$

Equation 30 的求解可以使用 CG 法（Algorithm 1）。解 Equation 30 对应正规方程

$$\mathbf{E}^H \mathbf{s} = (\mathbf{E}^H \mathbf{E} + \lambda \Phi^H \Phi) \hat{\mathbf{x}} \quad (31)$$

对应线性系统算子为 $\mathcal{A} = (\mathbf{E}^H \mathbf{E} + \lambda \Phi^H \Phi)$ 。需要指出，即使 $\mathbf{E}$ 欠采样，Tikhonov 正则化项的加入仍保证 $\mathcal{A}$ 的正定性，证明过程见第二章。

而对于非二阶可微正则化项 h 的优化问题，可使用加速梯度法（Accelerated Gradient Method，

¹²此处也将目标函数整体进行缩放，而最小值点不改变。

¹³对实图像 $\mathbf{x}$ ，解应取实部即 $\hat{\mathbf{x}} = (\text{Re}[\mathbf{E}^H \mathbf{E}] + \lambda \text{Re}[\Phi^H \Phi])^{-1} \text{Re}[\mathbf{E}^H \mathbf{s}]$ 。而此处沿用原文表述省略取实部，将解简化为 Equation 30 的形式。

AGM)，其迭代可写为

$$\mathbf{x}_t = \mathbf{z}_{t-1} - \gamma_t \nabla f(\mathbf{z}_{t-1}) \quad (32)$$

$$\mathbf{z}_t = \mathbf{x}_t + \frac{q_{t-1} - 1}{q_t} (\mathbf{x}_t - \mathbf{x}_{t-1}) \quad (33)$$

其中初值 $\mathbf{x}_0 = \mathbf{z}_0 \in \mathbb{C}^n$ ， $\gamma_t > 0$ 为步长。通过在每次迭代中自适应调整 $\{q_t\}$ ，AGM 的收敛速度可高于 GD 法。当 $q_t = 1$ （对所有 $t \geq 1$ ）时，AGM 退化为 GD 法。 $\{q_t\}$ 普遍设置为

$$q_t = \frac{1}{2} \left(1 + \sqrt{1 + 4q_{t-1}^2} \right), \quad q_0 = 1 \quad (34)$$

AGM 的步长可以通过回溯线搜索自适应调整。给定梯度向量 $\nabla f(\mathbf{z}_{t-1}) > 0$ 、初始步长 $\gamma_t > 0$ 以及参数 $\theta \in (0, 1/2]$ 和 $\beta \in (0, 1)$ ，回溯执行

$$\begin{aligned} \text{while } & f[\mathbf{z}_{t-1} - \gamma_t \nabla f(\mathbf{z}_{t-1})] > f(\mathbf{z}_{t-1}) - \theta \gamma_t \|\nabla f(\mathbf{z}_{t-1})\|_2^2 \\ \text{do } & \gamma_t \leftarrow \beta \gamma_t \end{aligned}$$

对于光滑函数 f ，该 while 循环在 γ_t 充分小后终止。

接下来讨论 AGM 的收敛速度。考虑优化问题的以下条件：

假设 1. 函数 $f = g + h$ 连续可微且凸。此外，梯度 ∇f 是 Lipschitz 连续¹⁴的且值为常数 $L > 0$ 。

假设 2. 函数 f 在某个 $\mathbf{x}^* \in \mathbb{C}^n$ 处存在有限最小值 $f^* = f(\mathbf{x}^*)$ ，使得 $\|\mathbf{x}_0 - \mathbf{x}^*\|_2 \leq R$ 。

当 f 二次连续可微时，假设 1 等价于条件 $\mathbf{0} \preceq \mathcal{H}f(\mathbf{x}) \preceq L\mathbf{I}$ ，其中 $\mathcal{H}f(\mathbf{x})$ 是 f 的 Hessian 矩阵。假设 2 认为最小值点到初值 $\mathbf{x}_0$ 的距离有界。基于以上两点假设可得：

定理 1. 在假设 1、2 下，使用固定步长 $0 < \gamma \leq 1/L$ 进行 $T \geq 1$ 次 AMG 迭代，则有

$$f(\mathbf{x}_{t-1}) - f^* \leq \frac{2R^2}{\gamma(t+1)^2} \quad (36)$$

Nesterov 证明，对于光滑凸函数，任何仅使用梯度信息的一阶方法的收敛速度不可能优于 $O(1/t^2)$ 。标准 GD 仅有 $O(1/t)$ 的收敛速度，而 AGM 通过 Equation 33 的类“动量”外推可以实现一阶方法的最优 $O(1/t^2)$ 收敛速度。

3.2 非光滑优化

MRI 中许多广泛使用的正则化器 $h(\cdot)$ 是非光滑的。一些著名的例子包括全变分（Total Variation, TV）[24, 6]、总广义变分（Total Generalized Variation, TGV）[25, 26] 和 Hessian Schatten-范

¹⁴Lipschitz 连续：对所有 $\mathbf{x}, \mathbf{y}$ ，有

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|_2 \leq L\|\mathbf{x} - \mathbf{y}\|_2 \quad (35)$$

其中 L 称为 Lipschitz 常数，限制了梯度变化的剧烈程度。

数 [27, 28]。例如，各向异性 TV 正则化的 MRI 重建可用以下项来表述

$$g(\mathbf{x}) = \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 \quad \text{和} \quad h(\mathbf{x}) = \lambda \|\Phi\mathbf{x}\|_1, \quad (37)$$

其中 $\lambda > 0$ 为正则化参数， Φ 表示沿图像 $\mathbf{x}$ 的每个维度计算的有限差分。

广泛使用的正则化器的不可微性导致了近端算法 [29] 在图像重建中的广泛采用，这些算法无需对 h 求导。在此背景下，两个广泛使用的算法是近端梯度法（Proximal Gradient Method, PGM）[30-33] 和交替方向乘子法（Alternating Direction Method of Multipliers, ADMM）[34-36]。使非光滑正则化器的优雅处理成为可能的关键概念是近端算子 [37]¹⁵，定义为

$$\text{prox}_{\lambda h}(\mathbf{z}) = \arg \min_{\mathbf{x} \in \mathbb{C}^n} \left\{ \frac{1}{2} \|\mathbf{x} - \mathbf{z}\|_2^2 + \lambda h(\mathbf{x}) \right\}, \quad \lambda > 0, \mathbf{z} \in \mathbb{C}^n. \quad (38)$$

到子集 $\mathcal{X} \subseteq \mathbb{C}^n$ 的投影是 $h(\cdot) = 1_{\mathcal{X}}(\cdot)$ 的近端算子，其中 $1_{\mathcal{X}}(\cdot)$ 为示性函数¹⁶，对任何 $\mathbf{x} \in \mathcal{X}$ 取值为 0，而对 $\mathbf{x} \notin \mathcal{X}$ 取值为 $+\infty$ 。尽管近端算子可为非凸函数定义，但当 h 为正常、闭合且凸时，其对每个 $\mathbf{z} \in \mathbb{C}^n$ 的存在性和唯一性得以保证 [38]。

算法 3 总结了 PGM 和加速 PGM（Accelerated Proximal Gradient Method, APGM）¹⁷（也称 FISTA），其中后者通过在 PGM 中简单地引入 Nesterov 加速而获得。

算法 3 PGM/APGM

```

1: input: 初始值  $\mathbf{x}_0 = \mathbf{z}_0$  和步长  $\gamma > 0$ 
2: for  $t = 1, 2, \dots$  do
3:    $\mathbf{u}_t \leftarrow \mathbf{z}_{t-1} - \gamma \nabla g(\mathbf{z}_{t-1})$  ▷ 更多数据一致性
4:    $\mathbf{x}_t \leftarrow \text{prox}_{\gamma h}(\mathbf{u}_t)$  ▷ 更多正则化
5:    $\mathbf{z}_t \leftarrow \mathbf{x}_t + \frac{q_{t-1} - 1}{q_t}(\mathbf{x}_t - \mathbf{x}_{t-1})$ 
6: end for

```

基于 ADMM 的图像重建通过将逆问题（Equation 26）重新表述为等价的约束优化问题而获得。算法 4 总结了 ADMM 用于如下约束形式

$$\min_{\mathbf{x}, \mathbf{z}} g(\mathbf{z}) + h(\mathbf{x}) \quad \text{满足约束} \quad \mathbf{z} = \mathbf{x}. \quad (39)$$

该约束问题然后可通过构建增广 Lagrangian 函数 [39]¹⁸与对偶变量 $\mathbf{s}$ ，并以交替方式对 $\mathbf{x}$ 、 $\mathbf{z}$ 和 $\mathbf{s}$

¹⁵近端算子的直观理解：（1） $\text{prox}_{\lambda h}(\mathbf{z})$ 寻求在“接近” $\mathbf{z}$ （通过 $\frac{1}{2} \|\mathbf{x} - \mathbf{z}\|_2^2$ 项）与“使 $h(\mathbf{x})$ 小”（通过 $\lambda h(\mathbf{x})$ 项）之间的平衡。（2）当 $h(\cdot) = 1_{\mathcal{X}}(\cdot)$ 为集合 $\mathcal{X}$ 的示性函数时，近端算子退化为到 $\mathcal{X}$ 的投影。（3）近端算子也可解释为 AWGN 去噪问题 $\mathbf{z} = \mathbf{x} + \boldsymbol{\eta}$ （其中 $\boldsymbol{\eta} \sim \mathcal{CN}(\mathbf{0}, \mathbf{I})$ ， $\mathbf{x} \sim p_{\mathbf{x}}$ ）的 MAP 估计器，只需令 $h(\mathbf{x}) = -\log p_{\mathbf{x}}(\mathbf{x})$ 。

¹⁶示性函数： $1_{\mathcal{X}}(\mathbf{x}) = 0$ 当 $\mathbf{x} \in \mathcal{X}$ ， $1_{\mathcal{X}}(\mathbf{x}) = +\infty$ 当 $\mathbf{x} \notin \mathcal{X}$ 。此时近端算子退化为 $\text{prox}_{1_{\mathcal{X}}}(\mathbf{z}) = \arg \min_{\mathbf{x} \in \mathcal{X}} \|\mathbf{x} - \mathbf{z}\|_2^2$ ，即到集合 $\mathcal{X}$ 的欧氏投影。

¹⁷APGM 与 FISTA：加速 PGM 也称快速迭代收缩/阈值算法（Fast Iterative Shrinkage-Thresholding Algorithm, FISTA）。当 $q_t = 1$ 对所有迭代成立时，算法对应传统 PGM；当按 Equation 34 更新 $\{q_t\}$ 时，得到 APGM/FISTA。APGM 通过在 PGM 中简单地引入 Nesterov 加速而获得，其收敛速度从 PGM 的 $O(1/t)$ 提升至 $O(1/t^2)$ 。

¹⁸增广 Lagrangian 函数：对约束问题 $\min_{\mathbf{x}, \mathbf{z}} g(\mathbf{z}) + h(\mathbf{x})$ s.t. $\mathbf{z} = \mathbf{x}$ ，其增广 Lagrangian 为

$$\mathcal{L}_{\gamma}(\mathbf{x}, \mathbf{z}, \mathbf{s}) = g(\mathbf{z}) + h(\mathbf{x}) + \mathbf{s}^T(\mathbf{x} - \mathbf{z}) + \frac{\gamma}{2} \|\mathbf{x} - \mathbf{z}\|_2^2, \quad (40)$$

进行优化来处理。可以考虑其他类似的变量分裂策略以获得 ADMM 的不同变体 [40]。

算法 4 ADMM

```

1: input: 初始值  $\mathbf{x}_0$  和惩罚参数  $\gamma > 0$ 
2: for  $t = 1, 2, 3, \dots$  do
3:    $\mathbf{u}_t \leftarrow \text{prox}_{\gamma g}(\mathbf{x}_{t-1} + \mathbf{z}_{t-1})$  ▷ 更多数据一致性
4:    $\mathbf{x}_t \leftarrow \text{prox}_{\gamma h}(\mathbf{u}_t - \mathbf{z}_{t-1})$  ▷ 更多正则化
5:    $\mathbf{z}_t \leftarrow \mathbf{z}_{t-1} + \mathbf{x}_t - \mathbf{u}_t$ 
6: end for

```

仔细考察 PGM/APGM 和 ADMM 可揭示这两类算法之间的若干相似性和差异性。两种算法均交替于通过分别应用算子 $\mathbf{I} - \gamma \nabla g$ 和 $\text{prox}_{\gamma g}$ 改善数据一致性，以及通过应用算子 $\text{prox}_{\gamma h}$ 对图像施加先验知识。PGM/APGM 和 ADMM 的每次迭代复杂度可能因评估相应操作的难度而显著不同。例如，对于 LS 项，我们有

$$\nabla g(\mathbf{x}) = \mathbf{E}^H(\mathbf{E}\mathbf{x} - \mathbf{s}) \quad (41)$$

和

$$\begin{aligned} \text{prox}_{\gamma g}(\mathbf{x}) &= \arg \min_{\mathbf{z} \in \mathbb{C}^n} \left\{ \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2 + \frac{\gamma}{2} \|\mathbf{E}\mathbf{z} - \mathbf{s}\|_2^2 \right\} \\ &= (\mathbf{I} + \gamma \mathbf{E}^H \mathbf{E})^{-1} (\mathbf{x} + \gamma \mathbf{E}^H \mathbf{s}), \end{aligned} \quad (42)$$

这通常用几次 CG 迭代求解¹⁹。

APGM 在凸函数上的收敛行为与 AGM 相同。为明确陈述，我们假设以下性质：

假设 3. 函数 g 连续可微且凸。此外，梯度 ∇g 是 Lipschitz 连续的，具有常数 $L > 0$ 。

假设 4. 函数 h 是正常、闭合且凸的。

假设 5. 函数 $f = g + h$ 具有有限最小值 $f^* = f(\mathbf{x}^*)$ 在某个 $\mathbf{x}^* \in \mathbb{C}^n$ 处取得，使得 $\|\mathbf{x}_0 - \mathbf{x}^*\|_2 \leq R$ 。

我们现在可以陈述以下优化中著名的结果（证明见 [33]）：

定理 2. 在假设 3-5 下，使用固定步长 $0 < \gamma \leq 1/L$ 运行 APGM $T \geq 1$ 次迭代。则该方法的迭代满足

$$f(\mathbf{x}_t) - f^* \leq \frac{2R^2}{\gamma(t+1)^2} \quad (43)$$

因此，APGM 是 AGM 的推广，保持了相同的最优最坏情况收敛速度²⁰。

ADMM 的收敛性也在文献中得到了广泛研究 [34-36, 40]。为陈述一个结果，我们采用以下假设：

假设 6. 函数 g 和 h 均为正常、闭合且凸的。

其中 $\mathbf{s}$ 为对偶变量（Lagrange 乘子）， $\gamma > 0$ 为惩罚参数。ADMM 交替极小化 $\mathcal{L}_\gamma$ 关于 $\mathbf{z}$ 、 $\mathbf{x}$ ，然后更新对偶变量 $\mathbf{s}$ 。算法 4 中的变量 $\mathbf{z}_t$ 实际上对应缩放后的对偶变量 $(\mathbf{s}/\gamma)$ 。

¹⁹PGM 与 ADMM 的对比：（1）PGM 使用 ∇g （显式梯度步），而 ADMM 使用 $\text{prox}_{\gamma g}$ （隐式近端步）——后者更昂贵但可能更稳定；（2）对于光滑的 g ， ∇g 计算简单（一次 $\mathbf{E}$ 和 $\mathbf{E}^H$ 应用），而 $\text{prox}_{\gamma g}$ 需要求解一个线性系统（通常用 CG 迭代）；（3）ADMM 通常在少量迭代内达到中等精度，但高精度收敛慢；PGM/APGM 的收敛行为更为均匀。

²⁰APGM 与投影梯度法：注意，当近端算子对应于投影时，APGM 退化为投影梯度法的加速变体。同样地，当 h 光滑时， $\text{prox}_{\gamma h}$ 近似于 $\mathbf{I} - \gamma \nabla h$ ，APGM 退化为 AGM。

假设 7. 强对偶性对 Equation 39 中的约束问题成立。

假设 6 简单地陈述了我们考虑的是一个凸优化问题。假设 7 的一个充分条件是 g 和 h 的定义域的内部具有公共向量（即它们的交集非空）。我们可以陈述以下经典结果（证明见 [40]）：

定理 3. 在假设 6 和 7 下，ADMM 迭代满足以下条件：

- 残差收敛：迭代趋近可行性

$$\lim_{t \rightarrow \infty} \|\mathbf{x}_t - \mathbf{z}_t\| = 0. \quad (44)$$

- 目标收敛：迭代的目标值趋近最优值

$$\lim_{t \rightarrow \infty} [g(\mathbf{z}_t) + h(\mathbf{x}_t)] = f^*. \quad (45)$$

在实践中，近端方法相比传统的基于次梯度或光滑化的技术提供了更快的收敛速度。APGM 和 ADMM 均显著快于 PGM，这在图 3.2 中 MRI 中 TV 正则化图像重建问题上得到了说明。注意 ADMM 的典型行为（在 [40] 中讨论），其中它在几十次迭代内收敛到中等精度，但收敛到高精度则较慢。ADMM 对中等精度的快速收敛使其适用于只需近似良好解的大规模图像重建。

3.3 原始-对偶算法

原始-对偶算法也可用于求解 MRI 中出现的各种优化问题。一个典型的原始目标函数可写为

$$\min_{\mathbf{x}} g(\mathbf{E}\mathbf{x}) + h(\mathbf{x}) \quad (\text{原始问题}), \quad (46)$$

其中 $g(\mathbf{E}\mathbf{x})$ 是数据保真项， $h(\mathbf{x})$ 是正则化项。Chambolle-Pock (CP) 算法 [41] 是一种一阶原始-对偶方法，求解以下鞍点问题²¹：

$$\min_{\mathbf{x}} \max_{\mathbf{v}} \langle \mathbf{E}\mathbf{x}, \mathbf{v} \rangle + h(\mathbf{x}) - g^*(\mathbf{v}) \quad (\text{原始-对偶问题}), \quad (47)$$

其中 $g^*(\mathbf{x})$ 是 $g(\mathbf{x})$ 的凸共轭 [9]。转向原始-对偶方法而非求解原始函数的理由直接在于 $g(\mathbf{E}\mathbf{x})$ 的近端算子的非平凡表述。我们可以容易地表述 $g^*(\mathbf{x})$ 和 $h(\mathbf{x})$ 的近端算子。我们交替对 $\mathbf{x}$ 和 $\mathbf{v}$ 执行近端梯度下降以根据算法 5 求解 Equation 47 中的优化问题。多年来，已提出多种原始-对偶方法的变体以求解光滑和非光滑优化问题 [41-48]。

$g(\mathbf{E}\mathbf{x})$ 可以是非光滑函数，如 hinge 损失 [49]、广义 hinge 损失 [50]、绝对损失 [51] 或 ϵ -不敏感损失 [52]。 $h(\mathbf{x})$ 可以是非光滑正则化器，如 lasso [53]、组 lasso [54]、稀疏组 lasso [55]、排他 lasso [56]、 $\ell_{1,\infty}$ 正则化器 [57] 或迹范数正则化器 [58]。

²¹原始-对偶与凸共轭： $g^*(\mathbf{v}) = \sup_{\mathbf{u}} \{\langle \mathbf{u}, \mathbf{v} \rangle - g(\mathbf{u})\}$ 是 g 的凸共轭（或 Fenchel-Legendre 变换）。鞍点问题 $\min_{\mathbf{x}} \max_{\mathbf{v}} \langle \mathbf{E}\mathbf{x}, \mathbf{v} \rangle + h(\mathbf{x}) - g^*(\mathbf{v})$ 与原始问题等价，因为 $\max_{\mathbf{v}} \{\langle \mathbf{E}\mathbf{x}, \mathbf{v} \rangle - g^*(\mathbf{v})\} = g(\mathbf{E}\mathbf{x})$ 。原始-对偶方法的关键动机在于：即使 $g(\mathbf{E}\mathbf{x})$ 的近端算子难以计算（由于 $\mathbf{E}$ 的存在）， $g^*(\mathbf{v})$ 的近端算子通常具有闭合形式。

算法 5 原始-对偶方法 [41, 42]

```
1: input: 初始值  $\mathbf{x}_0$ 、 $\bar{\mathbf{x}}_0$ 、 $\mathbf{v}_0$ 
2:  $t \leftarrow 0$ 
3: 选择步长  $\sigma > 0$  和  $\tau > 0$ , 使得  $\sigma\tau L^2 < 1$ , 其中  $L = \|\mathbf{E}\|$  为诱导范数, 以及  $\theta \in [0, 1]$ 
4: repeat
5:    $\mathbf{v}_{t+1} \leftarrow \text{prox}_{\sigma g^*}(\mathbf{v}_t + \sigma \mathbf{E} \bar{\mathbf{x}}_t)$  ▷ 对偶近端
6:    $\mathbf{x}_{t+1} \leftarrow \text{prox}_{\tau h}(\mathbf{x}_t - \tau \mathbf{E}^* \mathbf{v}_{t+1})$  ▷ 原始近端
7:    $\bar{\mathbf{x}}_{t+1} \leftarrow \mathbf{x}_{t+1} + \theta(\mathbf{x}_{t+1} - \mathbf{x}_t)$  ▷ 外推
8:    $t \leftarrow t + 1$ 
9: until 满足收敛/终止条件
```

4 小结

本章回顾了 MRI 图像重建背景下若干广泛使用的优化策略。这类算法所需的关键性质是利用关于未知图像 $\mathbf{x}$ 的有用先验信息的能力。我们讨论了处理光滑和非光滑正则化器的算法。

从最小二乘重建出发, 当 $\mathbf{E}$ 良态且全采样时, 闭合解可通过 Moore-Penrose 广义逆直接获得。在加速采样的欠定情形下, 必须借助迭代方法 (GD、CG) 求解。GD 的收敛条件取决于步长 γ 与 $\mathbf{E}^H \mathbf{E}$ 最大特征值的关系 (Equation 15), 而 CG 作为 Krylov 子空间方法可在至多 n 次迭代内精确求解线性系统。

随后, 我们将 MR 重建推广为一般正则化优化问题 $\min_{\mathbf{x}} g(\mathbf{x}) + h(\mathbf{x})$, 按照 h 的光滑性分为两类算法族:

1. **光滑优化:** 当 h 光滑时 (如 Tikhonov 正则化), 可使用 AGM 及其变体, 通过 Nesterov 动量外推达到最优 $O(1/t^2)$ 收敛速度 (定理 1)。
2. **非光滑优化:** 当 h 不可微时 (如 TV、 ℓ_1 正则化), 近端算法成为标准工具。PGM 通过显式梯度步 + 近端步交替工作, 其加速版本 APGM/FISTA 同样达到 $O(1/t^2)$ 速度 (定理 2)。ADMM 通过变量分裂将原问题转化为约束问题, 利用增广 Lagrangian 交替极小化, 在少量迭代内可达到中等精度 (定理 3)。原始-对偶 (Chambolle-Pock) 方法通过鞍点表述同时更新原始和对偶变量, 对具有复杂线性算子的非光滑项 (如 $g(\mathbf{E}\mathbf{x})$) 特别有效。

A 物理量符号及含义

符号	含义	单位/类型
$\mathbf{s}$	向量化 k 空间数据	$\mathbb{C}^m$
$\mathbf{x}$	向量化待重建图像	$\mathbb{C}^n$
$\hat{\mathbf{x}}$	重建图像估计	$\mathbb{C}^n$
$\mathbf{F}$	二维 Fourier 变换矩阵	$\mathbb{C}^{n \times n}$
$\mathbf{B}$	k 空间采样矩阵	$\{0, 1\}^{p \times n}$
$\mathbf{C}_c$	第 c 个线圈的灵敏度对角矩阵	$\mathbb{C}^{n \times n}$
$\mathbf{E}$	测量算子（正演模型矩阵）	$\mathbb{C}^{m \times n}$
ϵ	加性 Gaussian 噪声	$\mathbb{C}^m$
m	k 空间测量值总数 ($= pT$)	$\mathbb{N}$
n	图像像素/体素总数	$\mathbb{N}$
p	每线圈 k 空间采样点数	$\mathbb{N}$
T	接收线圈总数	$\mathbb{N}$
$\mathbf{E}^H$	$\mathbf{E}$ 的 Hermitian 转置	—
γ_t	第 t 次迭代的步长	$\mathbb{R}_+$
$\lambda_{\max}(\cdot)$	矩阵的最大特征值	—
$\mathbf{I}$	单位矩阵	无量纲
$\mathcal{A}(\cdot)$	CG 中的对称正定系统算子	—
$\mathbf{r}_t$	第 t 次迭代的残差向量	$\mathbb{C}^n$
$\mathbf{p}_t$	第 t 次迭代的搜索方向	$\mathbb{C}^n$
α_t	CG 中的步长参数	$\mathbb{R}$
β_t	CG 中的共轭方向参数	$\mathbb{R}$
$g(\mathbf{x})$	数据保真项	$\mathbb{R}$
$h(\mathbf{x})$	正则化器（先验项）	$\mathbb{R}$
$f(\mathbf{x})$	总目标函数 $= g(\mathbf{x}) + h(\mathbf{x})$	$\mathbb{R}$
λ	正则化参数	$\mathbb{R}_+$
Φ	稀疏变换矩阵	—
∇f	标量函数 f 的梯度	$\mathbb{C}^n$
$\nabla^2 f$	标量函数 f 的 Hessian 矩阵	$\mathbb{C}^{n \times n}$
L	Lipschitz 常数	$\mathbb{R}_+$
q_t	Nesterov 加速的过度松弛参数	$\mathbb{R}$
$\text{prox}_{\lambda h}(\cdot)$	函数 λh 的近端算子	—
$\mathbf{z}_t$	PGM/APGM/ADMM 中的辅助变量	$\mathbb{C}^n$
$\mathbf{u}_t$	算法中的中间变量	$\mathbb{C}^n$
$g^*(\cdot)$	$g(\cdot)$ 的凸共轭（Fenchel-Legendre 变换）	—
σ, τ	原始-对偶算法中的步长参数	$\mathbb{R}_+$
$L = \ \mathbf{E}\ $	$\mathbf{E}$ 的诱导矩阵范数（谱范数）	—
θ	原始-对偶算法中的外推参数	$[0, 1]$
$\langle \cdot, \cdot \rangle$	内积	—
f^*	f 的全局最小值	$\mathbb{R}$
R	初始点到最优解的距离上界	$\mathbb{R}_+$
$1_{\mathcal{X}}(\cdot)$	集合 $\mathcal{X}$ 的示性函数	—

B 术语中英文及缩写索引

下表按术语在正文中首次出现的先后顺序排列，页码为其首次出现位置。

中文术语	英文全称	缩写	页码
加性白 Gaussian 噪声	Additive White Gaussian Noise	AWGN	2
最大似然估计	Maximum Likelihood Estimation	MLE	2
最小二乘	Least Squares	LS	3
梯度下降	Gradient Descent	GD	3
共轭梯度	Conjugate Gradient	CG	5
最大后验概率	Maximum a Posteriori	MAP	??
加速梯度法	Accelerated Gradient Method	AGM	8
优化梯度法	Optimized Gradient Method	OGM	??
全变分	Total Variation	TV	8
总广义变分	Total Generalized Variation	TGV	8
近端梯度法	Proximal Gradient Method	PGM	9
交替方向乘法	Alternating Direction Method of Multipliers	ADMM	9
加速近端梯度法	Accelerated Proximal Gradient Method	APGM	9
快速迭代收缩/阈值算法	Fast Iterative Shrinkage-Thresholding Algorithm	FISTA	9
Chambolle-Pock 算法	Chambolle-Pock	CP	11
随机梯度下降	Stochastic Gradient Descent	SGD	??
Nesterov 加速梯度	Nesterov Accelerated Gradient	NAG	??
自适应矩估计	Adaptive Moment Estimation	ADAM	??
Nesterov 加速自适应矩估计	Nesterov-Accelerated Adaptive Moment Estimation	NADAM	??