

MR 重建中的优化算法

甘嘉程

2026 年 8-9 月

摘要

本报告基于《Magnetic Resonance Image Reconstruction: Theory, Methods, and Applications》第三章内容，从 MR 正向模型的基本形式出发，通过数学推导和伪代码演示梳理了 MR 图像重建中的优化算法。首先，报告主要讨论了在欠采样情形下最小二乘（Least Squares）重建的迭代方法，包括梯度下降法（Gradient Descent）与共轭梯度法（Conjugate Gradient）的迭代步、收敛条件和伪代码等。随后，报告关注正则化优化问题中的重建模型，以正则化项 h 的光滑性分类讨论了三类求解算法：光滑优化中的加速梯度法（Accelerated Gradient Method）；以全变分（Total Variation）为基础的 h 非光滑情形下的近端梯度法（Proximal Gradient Method）及其衍生算法；原始-对偶（Primal-dual）方法。报告推导了各算法的迭代步、近端算子与收敛性定理。

本报告对原文的数学推导与算法描述进行了进一步的勘误与补全。在学习本章的过程中，我进一步加深了对代数部分特别是矩阵代数的理解。此外，本章也让我初探优化算法原理。将 2-3 章放在一起看，我了解了 MR 在其物理原理以外的，关于信号采集后端图像重建的相关领域知识，在学习过程中，我最大的收获莫过于扩展了对于代数原理与应用的认知广度与深度。

1 MR 重建模型回顾与优化算法概述

首先来简要回顾第二章论述的 MR 重建问题的数学模型。MR 数据采集在 k 空间中进行，其对应于图像的 Fourier 变换。当全采样时， k 空间数据 $\mathbf{s} \in \mathbb{C}^p$ 与图像数据 $\mathbf{x} \in \mathbb{C}^n$ 间的正向模型

$$\mathbf{s} = \mathbf{F}\mathbf{x} \quad (1)$$

其中 $\mathbf{F}$ 表示二维 Fourier 变换矩阵，其元素 $F_{\mathbf{k}r} = \exp(-i2\pi\mathbf{k}_k^T\mathbf{r}_r)$ ， $\mathbf{k}_k \in \mathbb{R}^2$ 表示第 k 个 k 空间采样点的位置（ $\mathbf{k}_k^T$ 为其转置）， $\mathbf{r}_r \in \mathbb{R}^2$ 表示第 r 个像素的空间坐标。

在并行成像中，引入线圈空间灵敏度编码矩阵 $\mathbf{C}_c$ ，其是一个块对角矩阵，其对角线块为第 c 个线圈的空间灵敏度图。第 c 个线圈的全采样 k 空间数据为

$$\mathbf{s}_c = \mathbf{F}\mathbf{C}_c\mathbf{x} \quad (2)$$

当欠采样时, $p < n$, 设 $T \geq 1$ 为接收线圈数量, 则

$$\mathbf{s}_c = \mathbf{B}\mathbf{F}\mathbf{C}_c\mathbf{x} + \boldsymbol{\epsilon}_c \quad (3)$$

其中 $\mathbf{B} \in \mathbb{R}^{p \times n}$ 为采样矩阵, $\boldsymbol{\epsilon}_c \in \mathbb{C}^p$ 为线圈测量噪声。通过将所有线圈的测量值拼接为采样向量 $\mathbf{s} = (\mathbf{s}_1, \dots, \mathbf{s}_c, \dots, \mathbf{s}_T)$, 我们得到正向模型

$$\boxed{\mathbf{s} = \mathbf{E}\mathbf{x} + \boldsymbol{\epsilon}} \quad (4)$$

其中 $\mathbf{E} = \mathbf{B}\mathbf{F}\mathbf{C}_c \in \mathbb{C}^{T \times p \times n = m \times n}$ 位编码矩阵¹, $\boldsymbol{\epsilon} \in \mathbb{C}^m$ 为总测量噪声, 通常假设为加性白 Gaussian 噪声 (Additive White Gaussian Noise, AWGN)。

本章将讨论若干 MR 图像重建的优化策略。第二章论述了 MR 图像重建的数学基础是求解逆问题², 其中采集的 MR 数据 $\mathbf{s}$ 被图像先验知识所补全。不同的优化方法基于目标函数 (即数据保真项和正则化项) 的性质而产生。此外, 现代优化方法分为基于模型的重建方法和利用数据驱动先验的方法。在本章中, 将讨论不同迭代优化算法收敛性与收敛速度。

2 最小二乘重建

考虑Equation 4即从含噪测量值 $\mathbf{s} \in \mathbb{C}^m$ 重建图像 $\mathbf{x} \in \mathbb{C}^n$ 的逆问题。当 $\mathbf{E}$ 为良态矩阵³且 $m \geq n$ 时, 使用最大似然估计 (Maximum Likelihood Estimation, MLE) 重建 $\mathbf{x}$ 。对于 AWGN 模型, 可由 MLE 推导⁴具有闭合解的最小二乘 (Least Squares, LS) 问题⁵⁶

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} f(\mathbf{x}) = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 \quad (5)$$

其中 $f(\mathbf{x}) = \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2$ 称为 LS 问题的目标函数。

¹编码矩阵 $\mathbf{E}$ 无需为显式矩阵, 而是可以作为一个函数, 依次计算线圈灵敏度与图像像素乘积、Fourier 编码和子采样。

²在 MR 重建中, 逆问题的解通常通过优化一个目标函数来获得, 根据目标函数的性质 (如光滑性、凸性等), 产生了不同的优化方法。特别地, 在正则化问题中, 目标函数由数据保真项 (量化与测量数据的一致性) 和正则化项 (编码先验知识) 组成, 这种情况是普遍存在的 (见第二章)。

³良态矩阵 (Well-conditioned Matrix): 条件数 $\kappa(\mathbf{E}) = \|\mathbf{E}\| \cdot \|\mathbf{E}^\dagger\|$ 较小的矩阵。良态矩阵的测量噪声或近似误差经求解过程放大有限; 反之, 病态矩阵 (Ill-conditioned Matrix) 会放大微扰对解的影响。在全采样 (或过采样) 条件下, 良态条件保证 $\mathbf{E}$ 列满秩, 从而 $\mathbf{E}^H\mathbf{E}$ 正定可逆, Equation 5中的闭合解存在、唯一且数值稳定 (满足三个 Hadamard 条件), 确保可以使用 MLE 求解逆问题。

⁴推导过程见第二章。

⁵勘误: 原文 p.61(3.4) 出现 $\frac{1}{2}$ 因子, 与第二章 (28) 式系数不同。实际上, 对图像的估计 $\hat{\mathbf{x}}$ 取目标函数最小值点, 而目标函数整体缩放不影响最小值点, 故两式的解相同。而本章加入 $\frac{1}{2}$ 因子后, 目标函数的梯度为 $\mathbf{E}^H(\mathbf{E}\mathbf{x} - \mathbf{s})$ (推导过程见第二章), 与梯度下降 (Equation 9) 更新方向一致。而在 GD 迭代中, 目标函数缩放因子的差异被步长 γ 吸收: 本章收敛条件Equation 15包含了缩放因子的倒数, 若按第二章的写法则为 $0 < \gamma \leq 1/\lambda_{\max}(\mathbf{E}^H\mathbf{E})$ 。

⁶勘误: 最小二乘的目标函数 $\frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2$ 为实值函数, 本章所有梯度结果都应取实部。在本文中沿用了原文的表述, 省略了取实部。

接下来讨论Equation 5的求解。由于

$$\mathbf{E}^H \mathbf{E} = \sum_{c=1}^T \mathbf{C}_c^H \mathbf{F}^H \mathbf{B}^T \mathbf{B} \mathbf{F} \mathbf{C}_c \quad (6)$$

当问题维数（即 $\mathbf{E}$ 规模）很大时，Equation 6的计算和储存具有较高复杂度。若所有采样线圈的数据均为 k-空间全采样，即 $\mathbf{B} \in \mathbb{R}^{n \times n}$ 且 $m = Tn$ ，Equation 6可简化为对角矩阵

$$\mathbf{E}^H \mathbf{E} = \sum_{c=1}^T \mathbf{C}_c^H \mathbf{C}_c \Rightarrow \hat{\mathbf{x}} = (\mathbf{E}^H \mathbf{E})^{-1} (\mathbf{E}^H \mathbf{s}) = \left(\sum_{c=1}^T \mathbf{C}_c^H \mathbf{C}_c \right)^{-1} \sum_{c=1}^T \mathbf{C}_c^H \mathbf{F}^H \mathbf{s}_c \quad (7)$$

此时 $\hat{\mathbf{x}}$ 可以写出显式解需要满足 $\mathbf{E}^H \mathbf{E}$ 可逆，而全采样（或过采样）满足了这一条件。若使用欠采样并行采集，即 $\mathbf{B} \in \mathbb{R}^{p \times n}$ 且 $p < n$ ，则无法显式写出 $\mathbf{E}^H \mathbf{E}$ 及其逆，故也无法写出 $\hat{\mathbf{x}}$ 的显式解，需用梯度下降法或共轭梯度法等迭代方法求解Equation 5中的 LS 问题。接下来我们将逐一讨论。

2.1 梯度下降法

梯度下降（Gradient Descent, GD）法求解 LS 问题的基本原理是：在当前估计处计算目标函数的梯度，并以适当的步长沿梯度的负方向迭代更新估计。在这个过程中，GD 通过迭代尝试找到满足收敛条件的最小的 $\hat{\mathbf{x}}$ ，而负梯度的使用正是为了不断向下放缩 $\mathbf{x}_i$ 。

具体来说，对Equation 5中的 LS 目标函数 Taylor 展开到一阶

$$f(\mathbf{x}_{t-1} - \gamma \hat{\mathbf{e}}) \approx f(\mathbf{x}_{t-1}) - \gamma \hat{\mathbf{e}}^H \nabla f(\mathbf{x}_{t-1}) \quad (8)$$

其中 $\hat{\mathbf{e}}$ 为单位向量。代入其梯度 $\nabla f(\mathbf{x}) = \mathbf{E}^H (\mathbf{E} \mathbf{x} - \mathbf{s})$ ⁷可得，在第 t 次 GD 迭代中，当前估计 $\mathbf{x}_{t-1}$ 沿负梯度方向更新的估计

$$\mathbf{x}_t = \mathbf{x}_{t-1} - \gamma_t \nabla f(\mathbf{x}_{t-1}) = \mathbf{x}_{t-1} - \gamma_t \mathbf{E}^H (\mathbf{E} \mathbf{x}_{t-1} - \mathbf{s}) \quad (9)$$

其中 $\gamma_t > 0$ 为步长，可在每次迭代时调整或保持固定。GD 的收敛性和收敛速度取决于步长选择，步长过大可能导致发散，步长过小则收敛缓慢。GD 法的伪代码见Algorithm 1。

算法 1 求解最小二乘问题的梯度下降法（GD）

- 1: **input:** 初值 $\mathbf{x}_0$ 和步长 $\gamma_t > 0$
 - 2: $t \leftarrow 0$
 - 3: **repeat**
 - 4: $\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t - \gamma_t \mathbf{E}^H (\mathbf{E} \mathbf{x}_t - \mathbf{s})$ ▷ 负梯度方向更新
 - 5: $t \leftarrow t + 1$
 - 6: **until** 满足收敛/终止条件
-

⁷推导过程见第二章。

接下来讨论 GD 迭代解 Equation 9 收敛于 LS 问题 Equation 5 的解的条件。假设 GD 的初值为零向量 $\mathbf{x}_0 = \mathbf{0}$ ，且对所有 t 有 $\gamma_t = \gamma$ ，则递归写出

$$\mathbf{x}_t = (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}) \mathbf{x}_{t-1} + \gamma \mathbf{E}^H \mathbf{s} = \gamma \sum_{k=0}^{t-1} (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E})^k \mathbf{E}^H \mathbf{s} \quad (10)$$

由于当谱范数 $\|\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}\|_2 < 1$ 时⁸，矩阵几何级数 $\sum_k (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E})^k$ 收敛于 $(\gamma \mathbf{E}^H \mathbf{E})^{-1}$ ，此时

$$\lim_{t \rightarrow \infty} \mathbf{x}_t = \gamma (\gamma \mathbf{E}^H \mathbf{E})^{-1} \mathbf{E}^H \mathbf{s} = (\mathbf{E}^H \mathbf{E})^{-1} \mathbf{E}^H \mathbf{s} \quad (13)$$

即 GD 收敛于 Equation 5 的 LS 解。

记 Hermitian 正定矩阵 $\mathbf{E}^H \mathbf{E}$ 的特征值为 $0 < \lambda_1 \leq \dots \leq \lambda_n = \lambda_{\max}(\mathbf{E}^H \mathbf{E})$ ，则 $\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}$ 的特征值为 $1 - \gamma \lambda_i$ ($i = 1, \dots, n$)。对 Hermitian 矩阵⁹，收敛条件

$$\|\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E}\|_2 = \max |\lambda_i (\mathbf{I} - \gamma \mathbf{E}^H \mathbf{E})| = \max |1 - \gamma \lambda_i| < 1 \quad (14)$$

要求所有特征值满足 $|1 - \gamma \lambda_i| < 1$ ，则¹⁰

$$0 < \gamma \lambda_i < 2 \quad \Rightarrow \quad \gamma < \frac{2}{\lambda_i}, \quad \forall i \quad \Leftrightarrow \quad 0 < \gamma < \frac{2}{\lambda_{\max}(\mathbf{E}^H \mathbf{E})} \quad (15)$$

需要强调：1) 受 $\mathbf{E}$ 规模和 γ 的影响，GD 法可能不收敛或收敛非常缓慢；2) 上述讨论基于 GD 迭代解初值的选择，因此选定不同初值也可能影响 GD 法的收敛情况。

2.2 线性共轭梯度法

共轭梯度 (Conjugate Gradient, CG) 法适用于对称正定矩阵，其核心思路是：在每次迭代中，沿一个与所有先前迭代更新方向共轭的方向更新估计。这种迭代思路确保 CG 法在求解具有 n 个方程的方程组时在最多 n 次迭代内收敛。

⁸谱范数 (Spectral Norm)：矩阵 $\mathbf{A}$ 的谱范数由向量 ℓ_2 范数诱导，定义为

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|_2}{\|\mathbf{x}\|_2} \quad (11)$$

表示矩阵作用于向量后放大向量长度的最大倍数。 $\mathbf{A}$ 的谱范数等于其最大奇异值

$$\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^H \mathbf{A})} \quad (12)$$

总的来说，向量范数衡量向量自身的长度（如 ℓ_1 范数为分量绝对值之和， ℓ_2 范数为欧氏长度），而矩阵范数衡量矩阵对向量的拉伸能力。

⁹对 Hermitian 矩阵 $\mathbf{A}$ ，谱范数等于特征值绝对值中的最大值，即 $\|\mathbf{A}\|_2 = \max |\lambda_i(\mathbf{A})|$ 。利用该性质可将范数条件转化为特征值条件 $|1 - \gamma \lambda_i| < 1$ 。

¹⁰勘误：p.62(3.8) 对 γ 取值范围上界取等。事实上，当 $\gamma = 2/\lambda_{\max}$ 时， $1 - \gamma \lambda_{\max} = -1$ ，谱范数恰为 1，几何级数不收敛。因此，本文中 γ 取值范围为严格开区间。

设算符 $\mathcal{A}$ 由一个 $n \times n$ 对称正定矩阵定义，给定线性系统

$$\mathbf{y} = \mathcal{A}(\mathbf{x}) \quad (16)$$

如Equation 5给出的正规方程

$$\underbrace{\mathbf{E}^H \mathbf{s}}_{\mathbf{y}} = \underbrace{\mathbf{E}^H \mathbf{E} \mathbf{x}}_{\mathcal{A}(\mathbf{x})} \quad (17)$$

可用 CG 法求解。CG 法（Algorithm 2）的主要结构包括：1）应用一次算符 $\mathcal{A}$ 迭代更新残差 $\mathbf{r}_t$ ；2）步长 α_t 通过最小化残差 $\|\mathbf{r}_t\|_2^2$ 在搜索方向 $\mathbf{p}_t$ 上的二次型来解析计算，即

$$\alpha_t = \frac{\|\mathbf{r}_t\|_2^2}{\mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t)} \quad (18)$$

这等价于在当前搜索方向上的一维线搜索¹¹；3） β_t 确保新搜索方向 $\mathbf{p}_{t+1}$ 与所有先前方向关于 $\mathcal{A}$ 共轭，即 $\mathbf{p}_i^T \mathcal{A}(\mathbf{p}_j) = 0$ ($i \neq j$)。

算法 2 求解 $\mathbf{y} = \mathcal{A}(\mathbf{x})$ 的线性共轭梯度法

```

1: input: 初值  $\mathbf{x}_0$  和残差  $\mathbf{r}_0 = \mathbf{y} - \mathcal{A}(\mathbf{x}_0)$ 
2:  $t \leftarrow 0$ 
3:  $\mathbf{p}_0 \leftarrow \mathbf{r}_0$ 
4: repeat
5:    $\alpha_t \leftarrow \frac{\|\mathbf{r}_t\|_2^2}{\mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t)}$  ▷ 线搜索
6:    $\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t + \alpha_t \mathbf{p}_t$ 
7:    $\mathbf{r}_{t+1} \leftarrow \mathbf{r}_t - \alpha_t \mathcal{A}(\mathbf{p}_t)$  ▷ 更新残差
8:   if  $\|\mathbf{r}_t\|_2^2 \leq \text{阈值}$  then
9:     break
10:  end if
11:   $\beta_t \leftarrow \frac{\|\mathbf{r}_{t+1}\|_2^2}{\|\mathbf{r}_t\|_2^2}$  ▷ 共轭搜索系数
12:   $\mathbf{p}_{t+1} \leftarrow \mathbf{r}_{t+1} + \beta_t \mathbf{p}_t$ 
13:   $t \leftarrow t + 1$ 
14: until 满足收敛/终止条件

```

¹¹线搜索 (Line Search): 在沿搜索方向 $\mathbf{p}_t$ 确定步长 α_t 的过程中，把多维极小化约化为直线 $\{\mathbf{x}_t + \alpha \mathbf{p}_t : \alpha \in \mathbb{R}\}$ 上的一维优化

$$\min_{\alpha} f(\mathbf{x}_t + \alpha \mathbf{p}_t) \quad (19)$$

在线性 CG 中，线搜索有解析解。设目标函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathcal{A}(\mathbf{x}) - \mathbf{y}^T \mathbf{x}$ (与 $\|\mathcal{A}(\mathbf{x}) - \mathbf{y}\|_2^2$ 极小点相同的等价二次型)，令

$$\frac{d}{d\alpha} f(\mathbf{x}_t + \alpha \mathbf{p}_t) = \mathbf{p}_t^T [\mathcal{A}(\mathbf{x}_t) - \mathbf{y}] + \alpha \mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t) = 0 \quad (20)$$

$$\Rightarrow \alpha_t = \frac{\mathbf{p}_t^T (\mathbf{y} - \mathcal{A}(\mathbf{x}_t))}{\mathbf{p}_t^T \mathcal{A}(\mathbf{p}_t)} \quad (21)$$

约定残差 $\mathbf{r}_t = \mathbf{y} - \mathcal{A}(\mathbf{x}_t)$ 并利用正交性 $\mathbf{p}_t^T \mathbf{r}_t = \|\mathbf{r}_t\|_2^2$ ，可得步长公式Equation 18。而在非线性 CG 中，线搜索一般无解析解，需使用迭代线搜索方法。

2.3 非线性共轭梯度法

线性 CG 法可以视作极小化二次函数 $f(\mathbf{x}) = \|\mathcal{A}(\mathbf{x}) - \mathbf{y}\|_2^2$ ，而非线性 CG 法可以极小化任何可计算梯度的连续函数 $f(\mathbf{x})$ 。在非线性 CG 法中， β 的计算公式由 Fletcher-Reeves (FR)、Polak-Ribière (PR)、Hestenes-Stiefel (HS) 和 Dai-Yuan (DY) 给出

$$\beta_{t+1}^{\text{FR}} = \frac{\mathbf{r}_{t+1}^T \mathbf{r}_{t+1}}{\mathbf{r}_t^T \mathbf{r}_t} \quad (22)$$

$$\beta_{t+1}^{\text{PR}} = \frac{\mathbf{r}_{t+1}^T (\mathbf{r}_{t+1} - \mathbf{r}_t)}{\mathbf{r}_t^T \mathbf{r}_t} \quad (23)$$

$$\beta_{t+1}^{\text{HS}} = \frac{\mathbf{r}_{t+1}^T (\mathbf{r}_{t+1} - \mathbf{r}_t)}{-\mathbf{p}_t^T (\mathbf{r}_{t+1} - \mathbf{r}_t)} \quad (24)$$

$$\beta_{t+1}^{\text{DY}} = \frac{\mathbf{r}_{t+1}^T \mathbf{r}_{t+1}}{-\mathbf{p}_t^T (\mathbf{r}_{t+1} - \mathbf{r}_t)} \quad (25)$$

需要指出，一般函数 f 可能具有许多局部极小值，无法保证 CG 收敛到全局极小值。非线性 CG 法的伪代码见 [Algorithm 3](#)。

算法 3 极小化连续函数 $f(\mathbf{x})$ 的非线性共轭梯度法

```

1: input: 初始值  $\mathbf{x}_0$ 
2:  $t \leftarrow 0$ 
3:  $\mathbf{p}_0 \leftarrow \mathbf{r}_0 \leftarrow -\nabla f(\mathbf{x}_0)$ 
4: repeat
5:    $\alpha_t \leftarrow \arg \min_{\alpha_t} f(\mathbf{x}_t + \alpha_t \mathbf{p}_t)$  ▷ 线搜索
6:    $\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t + \alpha_t \mathbf{p}_t$ 
7:    $\mathbf{r}_{t+1} \leftarrow -\nabla f(\mathbf{x}_{t+1})$  ▷ 更新参差
8:   if  $\|\mathbf{r}_t\|_2^2 \leq \text{阈值}$  then
9:     break
10:  end if
11:   $\beta_{t+1} \leftarrow \beta_{t+1}^{\text{formula}}$  ▷ 使用 FR、PR、HS、DY 等公式，确定共轭搜索系数
12:   $\mathbf{p}_{t+1} \leftarrow \mathbf{r}_{t+1} + \beta_{t+1} \mathbf{p}_t$ 
13:   $t \leftarrow t + 1$ 
14: until 满足收敛/终止条件

```

3 基于模型的重建

当欠采样（即 $m < n$ ）时，将欠定逆问题表述为正则化问题

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} f(\mathbf{x}) = \arg \min_{\mathbf{x}} \{g(\mathbf{x}) + \lambda h(\mathbf{x})\} \quad (26)$$

其中 g 是数据保真项， h 是编码先验知识的正则化项， $\lambda > 0$ 是正则化参数。本节讨论正则化问题 [Equation 26](#) 的求解优化方法。[subsection 3.1](#) 讨论可微目标函数 f 的光滑优化方法，[subsection 3.2](#) 考虑适用于不可微正则化项的非光滑优化方法。

3.1 光滑优化

光滑优化的一种方法是基于 Tikhonov 正则化 (ℓ_2 范数正则化)。第二章指出, 任意线性矩阵 $\mathbf{L}$ 均可放入 Tikhonov 正则化项, 即

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \{ \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 + \lambda \|\mathbf{L}\mathbf{x} - \mathbf{x}^0\|_2^2 \} \quad (27)$$

可以得到 $\mathbf{x}$ 的显式解析解

$$\hat{\mathbf{x}} = (\text{Re} [\mathbf{E}^H \mathbf{E}] + \lambda \text{Re} [\mathbf{L}^H \mathbf{L}])^{-1} (\text{Re} [\mathbf{E}^H \mathbf{s}] + \lambda \text{Re} [\mathbf{L}^H] \mathbf{x}^0) \quad (28)$$

本节取 $\mathbf{L}$ 为稀疏变换 Φ , 设无参考图像先验即 $\mathbf{x}^0 = \mathbf{0}$, 则Equation 26中的 g 和 h 分别为¹²¹³

$$g(\mathbf{x}) = \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 \quad h(\mathbf{x}) = \frac{1}{2} \|\Phi \mathbf{x}\|_2^2 \quad (29)$$

$$\Rightarrow \boxed{\hat{\mathbf{x}} = (\mathbf{E}^H \mathbf{E} + \lambda \Phi^H \Phi)^{-1} (\mathbf{E}^H \mathbf{s})} \quad (30)$$

Equation 30的求解可以使用 CG 法 (Algorithm 2)。解Equation 30对应正规方程

$$\mathbf{E}^H \mathbf{s} = (\mathbf{E}^H \mathbf{E} + \lambda \Phi^H \Phi) \hat{\mathbf{x}} \quad (31)$$

对应线性系统算符 $\mathcal{A} = (\mathbf{E}^H \mathbf{E} + \lambda \Phi^H \Phi)$ 。需要指出, 即使 $\mathbf{E}$ 欠采样, Tikhonov 正则化项的加入仍保证 $\mathcal{A}$ 的正定性, 证明过程见第二章。

而对于非二阶可微正则化项 h 的优化问题, 可使用加速梯度法 (Accelerated Gradient Method, AGM), 其迭代可写为

$$\mathbf{x}_t = \mathbf{z}_{t-1} - \gamma_t \nabla f(\mathbf{z}_{t-1}) \quad (32)$$

$$\mathbf{z}_t = \mathbf{x}_t + \frac{q_{t-1} - 1}{q_t} (\mathbf{x}_t - \mathbf{x}_{t-1}) \quad (33)$$

其中初值 $\mathbf{x}_0 = \mathbf{z}_0 \in \mathbb{C}^n$, $\gamma_t > 0$ 为步长。通过在每次迭代中自适应调整 $\{q_t\}$, AGM 的收敛速度可高于 GD 法。当 $q_t = 1$ (对所有 $t \geq 1$) 时, AGM 退化为 GD 法。 $\{q_t\}$ 普遍设置为

$$q_t = \frac{1}{2} \left(1 + \sqrt{1 + 4q_{t-1}^2} \right), \quad q_0 = 1 \quad (34)$$

AGM 的步长可以通过回溯线搜索自适应调整。给定梯度向量 $\nabla f(\mathbf{z}_{t-1}) > 0$ 、初始步长 $\gamma_t > 0$ 以及

¹²此处也将目标函数整体进行缩放, 而最小值点不改变。

¹³对实图像 $\mathbf{x}$, 解应取实部即 $\hat{\mathbf{x}} = (\text{Re} [\mathbf{E}^H \mathbf{E}] + \lambda \text{Re} [\Phi^H \Phi])^{-1} \text{Re} [\mathbf{E}^H \mathbf{s}]$ 。而此处沿用原文表述省略取实部, 将解简化为Equation 30的形式。

$\theta \in (0, 1/2]$ 和 $\beta \in (0, 1)$ ，回溯执行

```

while  $f[\mathbf{z}_{t-1} - \gamma_t \nabla f(\mathbf{z}_{t-1})] > f(\mathbf{z}_{t-1}) - \theta \gamma_t \|\nabla f(\mathbf{z}_{t-1})\|_2^2$ 
    do  $\gamma_t \leftarrow \beta \gamma_t$ 

```

对于光滑函数 f ，该 while 循环在 γ_t 充分小后终止。AGM 的伪代码见 [Algorithm 4](#)。

算法 4 加速梯度法 (AGM)

```

1: input: 初始值  $\mathbf{x}_0 = \mathbf{z}_0$ 、 $q_0 = 1$ 、初始步长  $\gamma_t > 0$  及  $\theta$  和  $\beta$ 
2: for  $t = 1, 2, \dots$  do
3:   while  $f[\mathbf{z}_{t-1} - \gamma_t \nabla f(\mathbf{z}_{t-1})] > f(\mathbf{z}_{t-1}) - \theta \gamma_t \|\nabla f(\mathbf{z}_{t-1})\|_2^2$  do
4:      $\gamma_t \leftarrow \beta \gamma_t$  ▷ 回溯线搜索
5:   end while
6:    $\mathbf{x}_t \leftarrow \mathbf{z}_{t-1} - \gamma_t \nabla f(\mathbf{z}_{t-1})$  ▷ 梯度下降步
7:    $q_t \leftarrow \frac{1}{2} \left( 1 + \sqrt{1 + 4q_{t-1}^2} \right)$  ▷ 更新外推参数
8:    $\mathbf{z}_t \leftarrow \mathbf{x}_t + \frac{q_{t-1} - 1}{q_t} (\mathbf{x}_t - \mathbf{x}_{t-1})$  ▷ Nesterov 动量外推
9: end for

```

接下来讨论 AGM 的收敛速度。考虑优化问题的以下条件：

假设 1. 函数 $f = g + h$ 连续可微且凸。此外，梯度 ∇f 是 *Lipschitz* 连续¹⁴的且值为常数 $L > 0$ 。

假设 2. 函数 f 在某个 $\mathbf{x}^* \in \mathbb{C}^n$ 处存在有限最小值 $f^* = f(\mathbf{x}^*)$ ，使得 $\|\mathbf{x}_0 - \mathbf{x}^*\|_2 \leq R$ 。

当 f 二次连续可微时，假设 1 等价于条件 $\mathbf{0} \preceq \mathcal{H}f(\mathbf{x}) \preceq L\mathbf{I}$ ，其中 $\mathcal{H}f(\mathbf{x})$ 是 f 的 Hessian 矩阵。假设 2 认为最小值点到初值 $\mathbf{x}_0$ 的距离有界。基于以上两点假设可得：

定理 1. 在假设 1、2 下，使用固定步长 $0 < \gamma \leq 1/L$ 进行 $T \geq 1$ 次 AGM 迭代，则有

$$f(\mathbf{x}_{t-1}) - f^* \leq \frac{2R^2}{\gamma(t+1)^2} \quad (36)$$

Nesterov 证明，对于光滑凸函数，任何仅使用梯度信息的一阶方法的收敛速度不可能优于 $O(1/t^2)$ 。标准 GD 仅有 $O(1/t)$ 的收敛速度，而 AGM 通过 [Equation 33](#) 的类“动量”外推可以实现一阶方法的最优 $O(1/t^2)$ 收敛速度。

3.2 非光滑优化

常用的非光滑正则化器 h 有全变分 (Total Variation, TV)、总广义变分 (Total Generalized Variation, TGV) 和 Hessian Schatten-范数等，本节讨论求解这类问题的非光滑优化方法。以各向

¹⁴Lipschitz 连续：对所有 $\mathbf{x}, \mathbf{y}$ ，有

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|_2 \leq L\|\mathbf{x} - \mathbf{y}\|_2 \quad (35)$$

其中 L 称为 Lipschitz 常数，限制了梯度变化的剧烈程度。

异性 TV 正则化（ ℓ_1 范数正则化的一类）为例，令

$$g(\mathbf{x}) = \frac{1}{2} \|\mathbf{s} - \mathbf{E}\mathbf{x}\|_2^2 \quad h(\mathbf{x}) = \frac{1}{2} \|\Phi\mathbf{x}\|_1 \quad (37)$$

其中 Φ 表示沿图像 $\mathbf{x}$ 的每个维度计算的有限差分。对分片常数或分片光滑的图像，相邻像素的差分绝大多数为零，差分后的图像是稀疏的，故有限差分算子 Φ 是稀疏变换的一种具体实现，与第二章对 ℓ_1 范数正则化的讨论不矛盾。

由于绝对值函数在零点处不可导，故Equation 37中的 TV 正则化项不可微，此时可使用近端算法求解。定义近端算子为

$$\text{prox}_{\lambda h}(\mathbf{z}) = \arg \min_{\mathbf{x} \in \mathbb{C}^n} \left\{ \frac{1}{2} \|\mathbf{x} - \mathbf{z}\|_2^2 + \lambda h(\mathbf{x}) \right\}, \quad \lambda > 0, \mathbf{z} \in \mathbb{C}^n \quad (38)$$

其物理图像是：1) 寻求一个在“接近 $\mathbf{z}$ ”（通过数据保真项）与“使 $h(\mathbf{x})$ 小”（通过正则化项）之间的平衡的解；2) 令 $h(\mathbf{x}) = -\log p_{\mathbf{x}}(\mathbf{x})$ 也可解释为 AWGN 去噪问题

$$\mathbf{z} = \mathbf{x} + \boldsymbol{\eta}, \quad \boldsymbol{\eta} \sim \mathcal{CN}(\mathbf{0}, \lambda \mathbf{I}), \mathbf{x} \sim p_{\mathbf{x}} \quad (39)$$

的最大后验概率（Maximum a Posteriori, MAP）估计器。

对于光滑的 h ，传统梯度步 $\mathbf{x} = \mathbf{z} - \gamma \nabla h(\mathbf{z})$ 可视为将 h 在 $\mathbf{z}$ 处 Taylor 展开到一阶后求极小值点所得；而近端步 $\mathbf{x} = \text{prox}_{\gamma h}(\mathbf{z})$ 不对 h 作展开，而是直接求解子问题Equation 38的完整极小点。当 h 二次连续可微且 γ 充分小时， $\text{prox}_{\gamma h}(\mathbf{z}) = \mathbf{z} - \gamma \nabla h(\mathbf{z}) + O(\gamma^2)$ ¹⁵，近端步与梯度步之差为二阶小量。从求解的角度看，近端算子仅由正则化项 h 与各向同性二次项 $\frac{1}{2} \|\mathbf{x} - \mathbf{z}\|_2^2$ （使子问题强凸）组成。许多常用正则化器的近端算子具有闭式解。对于没有闭式解的近端步，可嵌套迭代算法以中等精度求解子问题Equation 38，而外层算法在近似求解子问题时仍保持收敛。

对Equation 37的 TV 项，近端算子为 TV 去噪子问题，可用近端梯度法（Proximal Gradient Method, PGM）和交替方向乘子法（Alternating Direction Method of Multipliers, ADMM）求解。PGM 和加速 PGM（Accelerated Proximal Gradient Method, APGM）¹⁶伪代码见Algorithm 5。基

算法 5 PGM/APGM

```

1: input: 初始值  $\mathbf{x}_0 = \mathbf{z}_0$  和步长  $\gamma > 0$ 
2: for  $t = 1, 2, \dots$  do
3:    $\mathbf{u}_t \leftarrow \mathbf{z}_{t-1} - \gamma \nabla g(\mathbf{z}_{t-1})$  ▷ 数据一致性
4:    $\mathbf{x}_t \leftarrow \text{prox}_{\gamma h}(\mathbf{u}_t)$  ▷ 正则化
5:    $\mathbf{z}_t \leftarrow \mathbf{x}_t + \frac{q_{t-1} - 1}{q_t} (\mathbf{x}_t - \mathbf{x}_{t-1})$  ▷ 使用 Nesterov 加速
6: end for

```

¹⁵由一阶最优条件 $\mathbf{x} = \mathbf{z} - \gamma \nabla h(\mathbf{x})$ 再对 $\nabla h(\mathbf{x})$ 展开可得。

¹⁶APGM 也称快速迭代收缩/阈值算法（Fast Iterative Shrinkage-Thresholding Algorithm, FISTA）。在 APGM/-FISTA 中 q_t 由Equation 34更新，其收敛速度从 PGM 的 $O(1/t)$ 提升至 $O(1/t^2)$ ；当 $q_t = 1$ （对所有 $t \geq 1$ ）时，APGM 退化为 PGM。

于 ADMM 的图像重建将正则化逆问题Equation 26表述为等价的约束问题，形如

$$\arg \min_{\mathbf{x}, \mathbf{z}} \{g(\mathbf{z}) + h(\mathbf{x})\} \quad \text{满足约束: } \mathbf{z} = \mathbf{x} \quad (40)$$

然后构建其增广 Lagrangian 函数

$$\mathcal{L}_\gamma(\mathbf{x}, \mathbf{z}, \mathbf{s}) = g(\mathbf{z}) + h(\mathbf{x}) + \mathbf{s}^T(\mathbf{x} - \mathbf{z}) + \frac{\gamma}{2} \|\mathbf{x} - \mathbf{z}\|_2^2 \quad (41)$$

其中 $\mathbf{s}$ 为对偶变量 (Lagrange 乘子), Algorithm 6 中的变量 $\mathbf{z}_t$ 实际上就对应缩放后的对偶变量 $\mathbf{s}/\gamma$, $\gamma > 0$ 为惩罚参数。ADMM 关于 $\mathbf{z}$ 、 $\mathbf{x}$ 交替极小化 $\mathcal{L}_\gamma$, 并更新对偶变量 $\mathbf{s}$, 伪代码见Algorithm 6。

算法 6 ADMM

```

1: input: 初始值  $\mathbf{x}_0$  和惩罚参数  $\gamma > 0$ 
2: for  $t = 1, 2, 3, \dots$  do
3:    $\mathbf{u}_t \leftarrow \text{prox}_{\gamma g}(\mathbf{x}_{t-1} + \mathbf{z}_{t-1})$  ▷ 数据一致性
4:    $\mathbf{x}_t \leftarrow \text{prox}_{\gamma h}(\mathbf{u}_t + \mathbf{z}_{t-1})$  ▷ 更多正则化
5:    $\mathbf{z}_t \leftarrow \mathbf{z}_{t-1} + \mathbf{x}_t - \mathbf{u}_t$ 
6: end for

```

接下来讨论 PGM/APGM 和 ADMM 的收敛性问题。两种算法分别应用算子 $\{\mathbf{I} - \gamma \nabla g\}$ 和 $\{\text{prox}_{\gamma g}\}$ 确保数据一致性, 并应用算子 $\{\text{prox}_{\gamma h}\}$ 施加先验知识。对于 LS 项有

$$\nabla g(\mathbf{x}) = \mathbf{E}^H(\mathbf{E}\mathbf{x} - \mathbf{s}) \quad (42)$$

$$\text{prox}_{\gamma g}(\mathbf{x}) = \arg \min_{\mathbf{z} \in \mathbb{C}^n} \left\{ \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|_2^2 + \frac{\gamma}{2} \|\mathbf{E}\mathbf{z} - \mathbf{s}\|_2^2 \right\} = (\mathbf{I} + \gamma \mathbf{E}^H \mathbf{E})^{-1} (\mathbf{x} + \gamma \mathbf{E}^H \mathbf{s}) \quad (43)$$

对比 PGM/APGM 与 ADMM: 1) PGM 使用显式梯度步 ∇g , 而 ADMM 使用近端步 $\text{prox}_{\gamma g}$, 后者复杂度和稳定性更高; 2) 对于光滑的 g , ∇g 计算相对简单, 而 $\text{prox}_{\gamma g}$ 需要 (通常使用 CG 迭代) 求解一个线性系统; 3) ADMM 通常在少量迭代内达到中等精度, 但高精度收敛慢, 相比之下 PGM/APGM 的收敛行为更为均匀。ADMM 的中等精度快速收敛性使其适用于只需近似良好解的大规模图像重建。此外, 从Figure 1中可知, 在实际应用中近端方法相较于光滑优化方法有更快的收敛速度。

具体来说, APGM 在凸函数上的收敛行为与 AGM 相同。我们作如下假设:

假设 3. 函数 g 连续可微且凸。此外, 梯度 ∇g 是 *Lipschitz* 连续的且值为常数 $L > 0$ 。

假设 4. 函数 h 是恰当、闭合且凸的。

假设 5. 函数 $f = g + h$ 在某个 $\mathbf{x}^* \in \mathbb{C}^n$ 处存在有限最小值 $f^* = f(\mathbf{x}^*)$, 使得 $\|\mathbf{x}_0 - \mathbf{x}^*\|_2 \leq R$ 。

定理 2. 在假设 3-5 下, 使用固定步长 $0 < \gamma \leq 1/L$ 进行 $T \geq 1$ 次 APGM 迭代, 则有

$$f(\mathbf{x}_t) - f^* \leq \frac{2R^2}{\gamma(t+1)^2} \quad (44)$$




图 1: PGM、APGM 和 ADMM 收敛速度对比

由此可知，APGM 保持了与 AGM 相同的最优收敛速度下限。

为讨论 ADMM 的收敛性，我们假设：

假设 6. 函数 g 和 h 均是恰当、闭合且凸的。

假设 7. 对约束问题 [Equation 40](#)，强对偶性成立。

假设 7 的一个充分条件是 g 和 h 的定义域交集非空。由此可得：

定理 3. 在假设 6、7 下，ADMM 迭代满足以下条件：

1. 残差收敛：迭代逼近可行性，即 $\lim_{t \rightarrow \infty} \|\mathbf{x}_t - \mathbf{z}_t\| = 0$ ；
2. 目标收敛：迭代的目标值趋近最优（最小值），即 $\lim_{t \rightarrow \infty} [g(\mathbf{z}_t) + h(\mathbf{x}_t)] = f^*$ 。

3.3 原始-对偶算法

在原始-对偶（Primal-dual）算法中，将原始目标函数写为

$$\min_{\mathbf{x}} \{g(\mathbf{E}\mathbf{x}) + h(\mathbf{x})\} \quad (\text{原始问题}) \quad (45)$$

其中 $g(\mathbf{E}\mathbf{x})$ 是数据保真项（可以非光滑）， $h(\mathbf{x})$ 是正则化项（可以非光滑）。接下来将讨论一种一阶原始-对偶方法：Chambolle-Pock 算法。设 $g^*(\mathbf{x})$ 是 $g(\mathbf{x})$ 的凸共轭¹⁷，将原始问题 [Equation 45](#) 表

¹⁷凸共轭（Convex Conjugate，也称 Fenchel-Legendre 变换）：函数 g 的凸共轭定义为

$$g^*(\mathbf{v}) = \sup_{\mathbf{u}} \{\langle \mathbf{u}, \mathbf{v} \rangle - g(\mathbf{u})\} \quad (46)$$

即对每个 $\mathbf{v}$ ，在所有 $\mathbf{u}$ 上取线性函数 $\langle \mathbf{u}, \mathbf{v} \rangle$ 与 $g(\mathbf{u})$ 之差的上确界。不论 g 是否凸，上确界 g^* 恒为凸函数。对光滑且凸的 g ，最优的 $\mathbf{u}$ 满足 $\nabla g(\mathbf{u}) = \mathbf{v}$ ，凸共轭相当于把自变量从点 $\mathbf{u}$ 换成斜率 $\mathbf{v}$ 。

述为以下鞍点问题¹⁸

$$\min_{\mathbf{x}} \max_{\mathbf{v}} \{ \langle \mathbf{E}\mathbf{x}, \mathbf{v} \rangle + h(\mathbf{x}) - g^*(\mathbf{v}) \} \quad (\text{原始-对偶问题}) \quad (49)$$

相较于直接使用近端算法, 原始-对偶方法的优点在于, $g(\mathbf{E}\mathbf{x})$ 的近端算子可能因 $\mathbf{E}$ 的存在而难以计算, 但对偶 $g^*(\mathbf{v})$ 的近端算子通常具有闭式形式, 容易写出 $g^*(\mathbf{x})$ 和 $h(\mathbf{x})$ 的近端算子。Algorithm 7 交替对 $\mathbf{x}$ 和 $\mathbf{v}$ 执行近端梯度下降以求解 Equation 49。

算法 7 原始-对偶方法

- 1: **input:** 初始值 $\mathbf{x}_0$ 、 $\bar{\mathbf{x}}_0$ 、 $\mathbf{v}_0$
 - 2: $t \leftarrow 0$
 - 3: 选择步长 $\sigma, \tau > 0$ s.t. $\sigma\tau L^2 < 1$ ¹⁹, 以及 $\theta \in [0, 1]$
 - 4: **repeat**
 - 5: $\mathbf{v}_{t+1} \leftarrow \text{prox}_{\sigma g^*}(\mathbf{v}_t + \sigma \mathbf{E}\bar{\mathbf{x}}_t)$ ▷ 对偶近端
 - 6: $\mathbf{x}_{t+1} \leftarrow \text{prox}_{\tau h}(\mathbf{x}_t - \tau \mathbf{E}^* \mathbf{v}_{t+1})$ ▷ 原始近端
 - 7: $\bar{\mathbf{x}}_{t+1} \leftarrow \mathbf{x}_{t+1} + \theta(\mathbf{x}_{t+1} - \mathbf{x}_t)$ ▷ 二阶外推
 - 8: $t \leftarrow t + 1$
 - 9: **until** 满足收敛/终止条件
-

¹⁸鞍点问题 (Saddle-point Problem): 形如 $\min_{\mathbf{x}} \max_{\mathbf{v}} L(\mathbf{x}, \mathbf{v})$ 的极小-极大值问题。点 $(\mathbf{x}^*, \mathbf{v}^*)$ 称为鞍点, 若对一切 $\mathbf{x}, \mathbf{v}$ 有

$$L(\mathbf{x}^*, \mathbf{v}) \leq L(\mathbf{x}^*, \mathbf{v}^*) \leq L(\mathbf{x}, \mathbf{v}^*) \quad (47)$$

即固定 $\mathbf{v}^*$ 时 $\mathbf{x}^*$ 极小化 L , 固定 $\mathbf{x}^*$ 时 $\mathbf{v}^*$ 极大化 L 。在此条件下, 函数沿两个方向弯曲相反, 形似马鞍面, 故称为鞍点。

在鞍点问题 Equation 49 中, $L(\mathbf{x}, \mathbf{v}) = \langle \mathbf{E}\mathbf{x}, \mathbf{v} \rangle + h(\mathbf{x}) - g^*(\mathbf{v})$, 其与原始问题 Equation 45 的等价性由凸共轭性质给出: 当 g 恰当、闭合且凸时, $g^{**} = g$ 。因此

$$\max_{\mathbf{v}} \{ \langle \mathbf{E}\mathbf{x}, \mathbf{v} \rangle - g^*(\mathbf{v}) \} = g^{**}(\mathbf{E}\mathbf{x}) = g(\mathbf{E}\mathbf{x}) \quad (48)$$

对每个 $\mathbf{x}$, 内层极大化复原出 $g(\mathbf{E}\mathbf{x})$, 外层对 $\mathbf{x}$ 极小化即与原始问题等价。

¹⁹ $L = \|\mathbf{E}\|$ 为诱导范数 (Induced Norm, 也称算子范数): 由向量范数诱导出的矩阵范数。设定义域、值域分别为赋以 ℓ_a 、 ℓ_b 向量范数的线性空间, 则矩阵 $\mathbf{A}$ 的诱导范数定义为

$$\|\mathbf{A}\|_{a,b} = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|_b}{\|\mathbf{x}\|_a} = \max_{\|\mathbf{x}\|_a=1} \|\mathbf{A}\mathbf{x}\|_b \quad (50)$$

即矩阵作用于向量后, 输出长度与输入长度之比的最大值。当两侧同取 ℓ_2 范数时, 诱导范数即谱范数 $\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A})$, 故此处 $L = \|\mathbf{E}\|$ 就是 $\mathbf{E}$ 的最大奇异值。

A 物理量符号及含义

符号	含义	单位/类型
$\mathbf{s}$	向量化 k 空间数据	$\mathbb{C}^m$
$\mathbf{x}$	向量化待重建图像	$\mathbb{C}^n$
p	每线圈 k 空间采样点数	$\mathbb{N}$
n	图像像素数	$\mathbb{N}$
$\mathbf{F}$	二维 Fourier 变换矩阵	$\mathbb{C}^{n \times n}$
$\mathbf{C}_c$	第 c 个线圈的灵敏度对角矩阵	$\mathbb{C}^{n \times n}$
T	接收线圈总数	$\mathbb{N}$
$\mathbf{B}$	k 空间采样矩阵	$\{0, 1\}^{p \times n}$
ϵ	加性白 Gaussian 噪声	$\mathbb{C}^m$
$\mathbf{E}$	编码矩阵	$\mathbb{C}^{m \times n}$
m	k 空间采样总数 ($= pT$)	$\mathbb{N}$
$\hat{\mathbf{x}}$	重建图像估计	$\mathbb{C}^n$
$\mathbf{E}^H$	$\mathbf{E}$ 的 Hermitian 转置	—
$\lambda_{\max}(\cdot)$	矩阵的最大特征值	—
∇f	标量函数 f 的梯度	$\mathbb{C}^n$
γ_t	第 t 次迭代的步长	$\mathbb{R}_+$
$\mathbf{I}$	单位矩阵	无量纲
$\sigma_{\max}(\cdot)$	矩阵的最大奇异值 (谱范数)	—
$\mathcal{A}(\cdot)$	CG 中的对称正定系统算子	—
α_t	CG 中的步长参数	$\mathbb{R}$
β_t	CG 中的共轭方向参数	$\mathbb{R}$
$g(\mathbf{x})$	数据保真项	$\mathbb{R}$
$h(\mathbf{x})$	正则化器项	$\mathbb{R}$
λ	正则化参数	$\mathbb{R}_+$
$\mathbf{L}$	Tikhonov 正则化中的线性矩阵	—
$\mathbf{x}^0$	参考图像先验	$\mathbb{C}^n$
Φ	稀疏变换矩阵	—
q_t	Nesterov 加速的过度松弛参数	$\mathbb{R}$
θ	回溯线搜索的接受参数/原始-对偶的外推参数	$\mathbb{R}$
β	回溯线搜索的收缩因子	$(0, 1)$
L	Lipschitz 常数	$\mathbb{R}_+$
$\mathbf{x}^*$	目标函数的最小值点	$\mathbb{C}^n$
f^*	f 的全局最小值	$\mathbb{R}$
R	初始点到最优解的距离上界	$\mathbb{R}_+$
$\mathcal{H}f$	标量函数 f 的 Hessian 矩阵	$\mathbb{C}^{n \times n}$
$\text{prox}_{\lambda h}(\cdot)$	函数 λh 的近端算子	—
$\mathcal{L}_\gamma$	约束问题的增广 Lagrangian 函数	—
$g^*(\cdot)$	$g(\cdot)$ 的等价性由凸共轭性质给出	—
$\langle \cdot, \cdot \rangle$	内积	—
σ, τ	原始-对偶算法中的步长参数	$\mathbb{R}_+$
$L = \ \mathbf{E}\ $	$\mathbf{E}$ 的诱导矩阵范数	—

B 术语中英文及缩写索引

下表按术语在正文中首次出现的先后顺序排列，页码为其首次出现位置。

中文术语	英文全称	缩写	页码
加性白 Gaussian 噪声	Additive White Gaussian Noise	AWGN	2
最大似然估计	Maximum Likelihood Estimation	MLE	2
最小二乘	Least Squares	LS	2
梯度下降	Gradient Descent	GD	3
共轭梯度	Conjugate Gradient	CG	4
加速梯度法	Accelerated Gradient Method	AGM	7
全变分	Total Variation	TV	8
总广义变分	Total Generalized Variation	TGV	8
最大后验概率	Maximum a Posteriori	MAP	9
近端梯度法	Proximal Gradient Method	PGM	9
交替方向乘子法	Alternating Direction Method of Multipliers	ADMM	9
加速近端梯度法	Accelerated Proximal Gradient Method	APGM	9
快速迭代收缩/阈值算法	Fast Iterative Shrinkage-Thresholding Algorithm	FISTA	9
原始-对偶算法	Primal-dual Algorithm	—	11